

分类号:

UDC:

学校代码: XXXXX

学 号: XXXXXXXXXXXX

基于单波束声呐和单目视觉结合的水下环境感知研究

Research on Underwater Environment Perception
Based on the Fusion of Single-Beam Sonar and
Monocular Vision

作 者:

指 导 教 师:

学 位 类 型:

专 业 名 称:

研 究 方 向:

授予学位单位: 中国海洋大学

日期:

学位论文答辩委员会

[illegible]

学位论文独创声明

本人所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得_____（注：如没有其他需要特别声明的，本栏可空）或其他教育机构的学位或证书使用过的材料。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律责任由本人承担。

学位论文作者签名：

日期：2026 年 5 月 17 日

学位论文版权使用授权书

本学位论文作者完全了解国家有关保留、使用学位论文的法律、法规和学校有关规定，并同意以下事项：

1. 学校有权保留并向国家有关部门或机构送交本学位论文的复印件和电子版，允许论文被查阅和借阅；
 2. 学校可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文；
 3. 学校可以基于教学及科研需要合理使用本学位论文。
- 需保密的学位论文在解密后适用本授权书。

学位论文作者签名：

导师签名：

日期：2026 年 5 月 17 日

日期：2026 年 5 月 17 日

摘 要

水下自主航行器是探索海洋资源的重要工具，但真实水下环境存在光照衰减、介质浑浊及流场扰动等多重干扰，加上非刚性障碍与动态生物目标的出现，使得航行器的环境感知与自主避障面临很大挑战。对此，本文提出一种态势感知驱动模型预测控制（SA-MPC）框架，构建了“感知-理解-决策-控制”的闭环，实现提前规避预测的高风险区域的自主决策。作为该框架的感知基础，针对水下深度估计受声学分辨率不足与光学成像退化影响、难以获得稠密且度量准确深度信息的问题，本文借鉴自动驾驶中利用稀疏深度点辅助视觉估计的思路，提出融合单波束声呐绝对测距与单目视觉相对深度的多模态深度感知方法，通过声呐定标与视觉扩散的互补，实现高分辨率且度量准确的深度估计，为后续设计的态势感知模型和模型控制架构提供可靠的几何支撑。通过复杂仿真场景与真实水域实验，本文验证了所提方法的准确性与工程可行性，主要研究工作与贡献如下：

第一，提出了一种面向单目视觉与单波束声呐的融合深度估计方法。针对传感器数据在模态与密度上的差异，设计了一种基于残差高斯扩散的融合机制，通过全局尺度对齐与局部自适应残差传播，将稀疏声呐测距值有效地融入稠密视觉深度图中，生成了高分辨率、度量精确的融合深度图，为环境理解提供了可靠的几何基础。

第二，构建了一个基于多源信息融合的水下态势感知模块。该模块以前述融合深度图为基础，结合 RGB 图像序列的时序动态特征，通过编码-解码网络结构实现对环境安全等级的像素级语义分割（安全、警告、危险）。该设计使其不仅能识别静态障碍物，更能有效感知水草、渔网等非刚性障碍及动态目标，提升了系统在视觉退化条件下的环境认知鲁棒性。

第三，设计了一种内嵌态势风险场的学习型模型预测控制器。为解决水下航行器动力学模型难以精确建模的问题，采用概率神经网络从数据中学习系统动态及其不确定性。将态势感知模块输出的语义安全场转化为可微分的空间风险势能，作为核心代价项嵌入 MPC 的滚动优化中，使控制器能在预测时域内主动规避风险区域，实现了从传统路径跟踪到风险预见性自主决策的范式转变。

第四，通过数值仿真与真实水域实验，对系统进行了全面验证。仿真结果表明，与传统全局规划结合局部跟踪的方法相比，SA-MPC 框架在路径长度、能耗与安全裕度等方面均有显著提升。近海实地实验验证了深度估计与态势感知模块；SA-MPC 框架在仿真中表现出优于传统方法的性能，系统整体运行满足轻量化平台的实时性要求。

本论文的创新性在于，将单波束声呐与单目视觉深度融合，并将其提升至态势理

解层次, 最终与数据驱动模型预测控制结合, 形成了一套完整的水下“感知-理解-决策-控制”自主避障架构。该工作为资源受限的水下机器人提供了一种低成本、高性能的自主避障解决方案, 对其在复杂开放水域中的实际应用具有理论与工程价值。

关键词: 水下态势感知; 深度融合; 单波束声纳; 模型预测控制; 水下航行器; 避障

ABSTRACT

Autonomous underwater vehicles (AUVs) are important tools for marine resource exploration. However, real underwater environments are subject to multiple disturbances, including illumination attenuation, medium turbidity, and flow field perturbations, together with the presence of non-rigid obstacles and dynamic biological targets, which pose significant challenges to environmental perception and autonomous obstacle avoidance. To address this issue, this dissertation proposes a situational-awareness-driven model predictive control (SA-MPC) framework, constructing a closed-loop architecture of “perception–understanding–decision–control” to enable autonomous decision-making that proactively avoids predicted high-risk regions. As the perceptual foundation of this framework, considering that underwater depth estimation is affected by limited acoustic resolution and optical degradation and thus cannot obtain dense and metrically accurate depth information, this work draws inspiration from the use of sparse depth points to assist visual estimation in autonomous driving and proposes a multi-modal depth perception method that fuses absolute range measurements from a single beam echo sounder (SBES) with relative depth estimated from monocular vision. Through the complementarity of acoustic calibration and visual diffusion, high-resolution and metrically accurate depth estimation is achieved, providing reliable geometric support for the subsequently designed situational awareness model and model predictive control architecture. Through complex simulation scenarios and real-world water experiments, the accuracy and engineering feasibility of the proposed method are validated. The main research work and contributions are as follows:

First, a fusion-based depth estimation method for monocular vision and single beam echo sounder is proposed. To address the differences in modality and data density between sensors, a fusion mechanism based on residual Gaussian diffusion is designed. Through global scale alignment and local adaptive residual propagation, sparse acoustic range measurements are effectively integrated into dense visual depth maps, generating high-resolution and metrically precise fused depth maps, which provide a reliable geometric foundation for environmental understanding.

Second, a multi-source information fusion-based underwater situational awareness module is constructed. Based on the aforementioned fused depth maps and combined with temporal dynamic features from RGB image sequences, an encoder–decoder network structure is employed to achieve pixel-level semantic segmentation of environmental safety levels (safe,

warning, and danger). This design enables not only the recognition of static obstacles but also the effective perception of non-rigid obstacles such as aquatic vegetation and fishing nets, as well as dynamic targets, thereby improving the robustness of environmental cognition under visual degradation conditions.

Third, a learning-based model predictive controller with an embedded situational risk field is designed. To address the difficulty of accurately modeling the dynamics of underwater vehicles, a probabilistic neural network is adopted to learn system dynamics and their uncertainty from data. The semantic safety field output by the situational awareness module is transformed into a differentiable spatial risk potential and embedded as a core cost term into the rolling optimization of MPC, enabling the controller to proactively avoid risk regions within the prediction horizon and realizing a paradigm shift from traditional trajectory tracking to risk-aware autonomous decision-making.

Fourth, comprehensive validation of the system is conducted through numerical simulations and real-world water experiments. Simulation results show that, compared with traditional methods combining global planning and local tracking, the SA-MPC framework achieves significant improvements in path length, energy consumption, and safety margin. Nearshore field experiments verify the depth estimation and situational awareness modules. The SA-MPC framework demonstrates superior performance compared with traditional methods in simulation, and the overall system operation satisfies the real-time requirements of lightweight platforms.

The innovation of this dissertation lies in fusing single beam echo sounder and monocular vision depth estimation, elevating it to the level of situational understanding, and ultimately integrating it with data-driven model predictive control to form a complete underwater “perception–understanding–decision–control” autonomous obstacle avoidance architecture. This work provides a low-cost and high-performance autonomous obstacle avoidance solution for resource-constrained underwater robots and has theoretical and engineering value for their practical application in complex open-water environments.

Key Words: Underwater Situational Awareness; Depth Fusion; Single-beam Sonar; Model Predictive Control; Underwater Vehicle; Obstacle Avoidance

目 录

摘要	I
Abstract	III
图表清单	XI
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	3
1.2.1 水下深度估计	3
1.2.2 多传感器融合	4
1.2.3 水下态势感知	5
1.2.4 水下避障算法	7
1.3 本文的研究内容以及章节安排	8
1.4 本章小结	9
2 相关工作技术	11
2.1 水下数据收集	11
2.1.1 数据来源	11
2.1.2 水下数据特征	16
2.2 相关技术介绍	17
2.2.1 单波束回声探测器原理	17
2.2.2 多传感器融合及深度估计理论	21
2.2.3 态势评估准则理论	24
2.2.4 水下航行器避障控制理论	26
2.3 水下环境感知与避障系统架构	28
2.4 本章小结	29
3 基于单波束声呐的水下单目深度估计	31
3.1 方法概述	31
3.2 传感器标定与跨模态数据配准	31

3.3	深度融合网络框架设计	34
3.3.1	整体架构	34
3.3.2	单目相对深度估计网络	35
3.3.3	基于 SBES 的绝对深度优化	38
3.4	损失函数与训练策略	39
3.5	实验与分析	41
3.5.1	实验设置与评估指标	41
3.5.2	深度估计性能对比	41
3.5.3	融合策略消融实验	43
3.5.4	真实水下环境测试	45
3.6	本章小结	46
4	基于视觉-SBES 融合的态势感知	48
4.1	方法概述	48
4.2	态势感知网络架构设计	49
4.2.1	整体架构	49
4.2.2	动态信息提取	50
4.2.3	特征融合网络设计	52
4.3	损失函数与训练策略	55
4.3.1	加权交叉熵损失	55
4.3.2	训练策略	56
4.4	实验与分析	56
4.4.1	评估指标	56
4.4.2	消融实验	57
4.4.3	对比实验	60
4.4.4	实时性分析	62
4.5	本章小结	63
5	基于态势感知的模型预测控制	64
5.1	HoloOcean 仿真平台	64

5.2	SA-MPC 框架	65
5.2.1	空间风险势场构建	66
5.2.2	学习型概率动力学模型	67
5.2.3	模型预测控制器	68
5.3	实验与分析	69
5.3.1	学习型动力学模型验证	69
5.3.2	避障性能仿真对比实验	71
5.4	本章小结	76
6	结论与展望	78
6.1	结论	78
6.2	展望	78
	参考文献	80
	攻读硕士学位期间取得的研究成果	87
	致谢	88
	作者简介	89

Contents

Figure list & Table list	XI
1 Introduction	1
1.1 Research Background and Significance	1
1.2 Current Research Status	3
1.2.1 Underwater Depth Estimation	3
1.2.2 Multi-Sensor Fusion	4
1.2.3 Underwater Situation Perception	5
1.2.4 Underwater Obstacle Avoidance Algorithm	7
1.3 Research Content and Chapter Arrangement	8
1.4 Chapter Summary	9
2 Related Work Techniques	11
2.1 Underwater Data Collection	11
2.1.1 Data Sources	11
2.1.2 Data Characteristics	16
2.2 Related Techniques	17
2.2.1 Principle of Single-Beam Echo Sounder	17
2.2.2 Multi-Sensor Fusion and Depth Estimation Theory	21
2.2.3 Situation Assessment Criteria Theory	24
2.2.4 Underwater Vehicle Obstacle Avoidance Control Theory	26
2.3 Underwater Environment Perception and Obstacle Avoidance System Archi- tecture	28
2.4 Chapter Summary	29
3 Underwater Monocular Depth Estimation Based on Single-Beam Sonar 31	
3.1 Method Overview	31
3.2 Sensor Calibration and Cross-Modal Data Registration	31

3.3	Fusion Network Framework Design	34
3.3.1	Overall Architecture	34
3.3.2	Monocular Relative Depth Estimation Network	35
3.3.3	SBES-Based Absolute Depth Refinement	38
3.4	Loss Functions and Training Strategy	39
3.5	Experiments and Analysis	41
3.5.1	Experimental Setup and Evaluation Metrics	41
3.5.2	Depth Estimation Performance Comparison	41
3.5.3	Ablation Study on Fusion Strategies	43
3.5.4	Real-world Underwater Environment Test	45
3.6	Chapter Summary	46
4	Vision-SBES Fusion based Situational Awareness	48
4.1	Method Overview	48
4.2	Situational Awareness Network Architecture Design	49
4.2.1	Overall Architecture	49
4.2.2	Dynamic Information Extraction	50
4.2.3	Feature Fusion Network Design	52
4.3	Loss Functions and Training Strategy	55
4.3	Weighted Cross-Entropy Loss	55
4.3	Training strategy	56
4.4	Experiments and Analysis	56
4.4	Evaluation Metrics	56
4.4	Ablation Study	57
4.4	Comparative Experiments	60
4.4.4	Real-time Performance Analysis	62
4.5	Chapter Summary	63
5	Situational Awareness Model Predictive Control	64
5.1	HoloOcean Simulator Platform	64
5.2	SA-MPC Framework	65

5.2	Construction of Spatial Risk Potential Field	66
5.2.2	Learning-based Probabilistic Dynamics Model	67
5.2.3	Model Predictive Controller	68
5.3	Experiments and Analysis	69
5.3.1	Validation of the Learned Dynamics Model	69
5.3.2	Simulation Comparison of Obstacle Avoidance Performance	71
5.4	Chapter Summary	76
6	Conclusion and Future Work	78
6.1	Conclusion	78
6.2	Future Work	78
	References	80
	Published papers and research results	86
	Acknowledgements	88
	Resume	89

图表清单

图 1-1	自主水下航行器 (AUV) 在复杂水下环境中的作业场景示意图	2
图 2-1	FLSeas VI 数据集。第一行图像为原图，第二行图像为对应的深度图	12
图 2-2	Sea-thru 数据集。第一行图像为原图，第二行图像为对应的深度图	13
图 2-3	自建验证数据集采集装置与场景，包含水下拍摄图像、相机与声呐布局示意图以及宏观实验场景布置	14
图 2-4	UVSA 数据集中的原始水下场景示例	15
图 2-5	UVSA 数据集标注示例：上方为原始水下图像，下方为对应的态势评估标注图（红色：危险，黄色：警告，绿色：安全）	16
图 2-6	水下图像质量退化问题综合示意图。图中展示了 (a) 低对比度、(b) 颜色失真、(c) 光照不均匀、(d) 浑浊、(e) 光反射及 (f) 光衰减等多种典型水下成像问题	17
图 2-7	P30e 单波束回声探测仪外观图	18
图 2-8	P30e 单波束回声探测仪测量原理示意图	19
图 2-9	PingViewer 软件上位机界面示意图	20
图 2-10	晚融合-双编码器网络结构示意图	22
图 2-11	晚融合-双编码器-解码器网络结构示意图	23
图 2-12	全局和局部深度预测网络结构示意图	23
图 2-13	Liu 等人提出的 SBES 与图像特征融合双编码器网络结构	24
图 2-14	Endsley 态势感知模型	25
图 2-15	深度模型预测视觉伺服控制框架示意图	27
图 2-16	水下态势评估与避障系统整体架构	29

图 3-1	SBES-相机融合系统的几何模型	32
图 3-2	掩码生成流程: (a) 原始图像, (b) 前景分割后的图像, (c) 与回声测深仪结合后的掩码图像, (d) 稀疏处理后的掩码图像	33
图 3-3	不同距离下的数据预处理流程及结果	34
图 3-4	深度融合模块的详细流程	35
图 3-5	DINOv2 数据预处理流程	36
图 3-6	密集预测变换器 (DPT) 架构	37
图 3-7	ZoeDepth 架构	37
图 3-8	各个模型在 MiDaS 策略上的性能比较	40
图 3-9	深度估计定性对比	42
图 3-10	人工平台系统	43
图 3-11	不同物体上各融合策略的深度估计性能对比	44
图 3-12	真实水下环境测试平台 (青岛近岸)	46
图 3-13	实验水下环境中的 RGB 图像与深度估计结果	46
图 4-1	基于视觉-SBES 融合的态势感知框架	48
图 4-2	态势感知模块网络详细架构	49
图 4-3	多步预测差分模块示意图	50
图 4-4	U-Net 网络结构	52
图 4-5	scSE 注意力模块结构	54
图 4-6	不同特征组合的消融实验结果可视化	58
图 4-7	训练过程中各项指标的变化趋势	59
图 4-8	不同方法在典型水下场景中的分割效果对比	61
图 4-9	不同测试环境下态势感知结果的可视化比较。子图 (a)– (i) 对应于模拟海上环境下的实验结果, 展示了模型在不同 水下条件下的感知能力; 子图 (j)–(r) 对应于青岛近岸水域 的实地试验结果, 反映了模型在真实水下环境中对多目标 及障碍物的态势感知表现	62
图 5-1	HoloOcean 系统架构概览	64

图 5-2	HoloOcean 传感器可视化工具演示	65
图 5-3	HoloOcean 预设仿真环境示例	66
图 5-4	SA-MPC 框架整体架构	66
图 5-5	预测误差随预测时域的变化曲线	70
图 5-6	不同状态维度的预测误差	71
图 5-7	概率与确定性模型的轨迹预测对比	72
图 5-8	SA 模型在 HoloOcean 仿真环境中的部署	74
图 5-9	仿真环境与避障轨迹对比	75
表 2-1	FLSeas VI 数据集场景与深度分布统计	12
表 2-2	Sea-thru 数据集场景与深度分布统计	13
表 2-3	P30e 单波束回声探测仪技术参数	21
表 2-4	态势评估准则表	25
表 2-5	水下环境区域类型评估与标注标准	25
表 3-1	深度估计性能定量比较	42
表 3-2	不同融合策略性能定量对比	45
表 4-1	不同输入特征组合下的态势感知性能对比	59
表 4-2	不同方法在 UVSA 数据集上的性能对比	60
表 5-1	水流扰动配置参数	70
表 5-2	HoloOcean 仿真环境关键配置参数	73
表 5-3	仿真环境中导航算法的性能指标	76

1 绪论

1.1 研究背景与意义

海洋是高质量发展的战略要地，也是实现中华民族伟大复兴的重要蓝色疆域。党的二十大报告作出了“发展海洋经济，保护海洋生态环境，加快建设海洋强国”的战略部署，为我国海洋事业发展指明了前进方向。2024 年《政府工作报告》进一步提出要“大力发展海洋经济”并将其作为培育新增长引擎的关键领域之一。在此国家战略牵引下，向深海进军、全面提升海洋观测、开发和保护能力已成为科技创新的紧迫任务。智慧化、自主化的海洋装备是认知海洋、经略海洋的核心工具。

海洋覆盖了地球超过百分之七十的表面积，作为生命的摇篮、气候的调节器与资源的宝库，其探索与可持续开发对人类社会的未来发展具有至关重要的战略意义。我国领海面积很广，发展潜力也大；因此，我们需要更有效地利用海洋资源，一方面是为了促进经济健康发展，另一方面也是为了更好地保障海洋战略安全^[1]。从海底资源勘探、生态环境监测到水下基础设施维护与国防安全，深入理解与利用海洋已成为全球科技竞争的前沿阵地。不过，海洋环境确实很恶劣。海上常有狂风暴雨这样的极端天气；而随着水深不断增加，海水的流速、温度、压强和盐度也会跟着发生变化。因此，考虑到海洋环境的复杂变化，以及载人水下航行器可能带来的风险和操作成本，水下无人系统的部署越来越受到重视。这类系统能够在深海和极端环境中，执行高风险任务，减少对人类的依赖^[2]。在这一背景下，自主水下航行器（Autonomous Underwater Vehicle, AUV）因其可替代或辅助人类，在危险、远海环境中完成长期、复杂任务，已成为拓展海洋活动的重要智能装备（图1-1展示了 AUV 的典型应用场景）。

与结构化的陆地或空中环境截然不同，水下环境是一个极具挑战的感知与决策“禁区”。其复杂性主要体现在以下几个方面：首先，光学感知严重退化。水体对光线的吸收与散射效应导致严重的视觉衰减、颜色失真与对比度下降，有效视距大幅缩短，传统依赖于清晰视觉的算法性能急剧下降。其次，环境动态且不确定。不仅存在复杂的水流扰动，更充斥着大量如摇曳的水草、废弃的渔网、漂浮的绳索等非刚性、可变形的障碍物，以及鱼群等动态生物目标。这些障碍物难以用简单的几何模型描述，对 AUV 的实时感知与避障构成了巨大威胁。最后，传感器性能受限。低成本轻量化 AUV 通常无法搭载昂贵且笨重的多波束声呐或水下激光雷达，其主要感知手段依赖于单目相机与单波束回声测深仪（SBES）等低成本传感器，但二者均存在固有缺陷。

在上述挑战中，高精度、高可靠的水下深度估计是构建一切高级自主能力的基




图 1-1 自主水下航行器（AUV）在复杂水下环境中的作业场景示意图

Fig. 1-1 Schematic diagram of the operation scene of autonomous underwater vehicles (AUVs) in complex underwater environments

石。精确的三维几何感知是 AUV 进行自身定位、环境建模、障碍物检测与避障路径规划的根本前提。然而，现有主流深度感知方案在水下面临严峻挑战：基于光学的方法（如单目/立体视觉）受水质影响极大，且存在固有的尺度模糊问题，难以直接获取度量准确的绝对深度；基于声学的方法（如多波束声呐）虽能获得绝对距离，但空间分辨率低、数据稀疏，且成本高昂，难以满足轻量化平台对精细避障的需求。因此，如何融合单目相机与单波束声呐这两种低成本、互补性强的传感器，在资源受限的条件下实现尺度准确、分辨率高、实时性强的深度估计，是推动轻量化 AUV 走向实用化必须攻克的首个关键难题。

获得精确的深度图仅是第一步。要让 AUV 像经验丰富的潜航员一样“理解”周围环境并做出智能决策，需要更高层次的认知能力——态势感知。态势感知不仅要求系统“看到”障碍物，更要“理解”其潜在风险，并能“预测”其未来状态。例如，一片漂浮的海藻与一块坚硬的礁石，虽然可能在深度图上呈现相似的突起，但对 AUV 构成的威胁类型与紧急程度截然不同。传统的基于目标检测或语义分割的感知框架缺乏这种深层次的风险推理与时空关联能力，无法为在动态复杂水域中的自主避障提供足够的决策依据。将精确的深度感知与高层次的态势理解相结合，并最终转化为安全、平滑、高效的运动控制，构成一个完整的自主智能闭环，是本领域研究的终极目标之一。模型预测控制（MPC）作为一种优秀的优化控制框架，因其能够显式处理系统约束并进行前向滚动优化，非常适合 AUV 的轨迹跟踪与避障。然而，传统 MPC 通常依赖于预先定义的、静态的环境代价地图，未能将实时、细粒度、富含语义的态势感知信息深度融入优化过程中，导致“感知”与“控制”之间仍存在隔阂。

综上所述，针对轻量化 AUV 在复杂未知水下环境中对“精确感知—深度理解—

智能决策”的迫切需求，本文研究工作的核心意义在于：系统性地探索并实现一套从多模态紧耦合深度估计，到时空语义态势理解，再到风险预见性模型预测控制的完整技术链条。本研究不仅旨在理论上解决单一传感器局限、感知与控制割裂等关键科学问题，更致力于工程上为低成本、高性能的轻量化 AUV 提供一套切实可行的自主避障解决方案，对其在海洋科研、资源开发、环境监测等领域的广泛应用具有重要的推动价值。

1.2 国内外研究现状

1.2.1 水下深度估计

水下深度估计对于海洋勘探和机器人应用至关重要，是自主水下航行器实现环境感知与自主导航的核心基础。在水下环境中，深度估计面临多种挑战，其主要解决方法可分为基于光学和基于声学两大类，各具独特的优势与局限性。传统基于光学模型的方法，如暗通道先验 (DCP)^[3]、红通道先验 (RCP)^[4] 和最小信息损失先验 (MILP)^[5]，通过估计透射图和反向散射常数来实现深度估计。随后，最大衰减识别 (MAI)^[6] 和图像模糊背景光中和 (IBLN)^[7] 等技术被提出以减少水下图像中光衰减和背景光的影响。Drews 等人基于暗通道先验提出的 UDCP 方法^[8] 专门针对水下环境，通过利用红、绿、蓝通道在水下衰减率的差异进行深度估计。Peng 等人^[9] 则提出基于图像模糊程度估计深度的三步法。Berman 等人^[10] 建立了更全面的物理图像形成模型，结合多光谱剖面恢复深度与颜色。然而，这些基于物理模型的方法普遍依赖于对背景光、透射图和水体衰减系数等参数的精确估计，而这些参数在复杂多变的真实水下环境中难以稳定获取，限制了其在实际应用中的鲁棒性。

随着深度学习技术的快速发展，基于学习的方法逐渐成为水下深度估计研究的热点。Yu 等人设计的 UDepth^[11] 为低成本水下机器人提供了高效的 3D 感知能力。Eigen 等人^[12] 开创性地将卷积神经网络引入单目深度估计领域，提出一种由粗粒度网络和细粒度网络组成的双网络框架，通过全局与局部信息的结合来解决深度估计问题，并启发了后续大量研究。Laina 等人^[13] 采用基于 ResNet 的全卷积残差网络进行深度回归，在提升实时性的同时保证了高分辨率输出。Cao 等人^[14] 和 Bhat 等人提出的 AdaBins^[15] 则将深度估计建模为分类或自适应区间回归问题，提升了精度并减少了伪影。然而，为陆地环境开发的最先进的单目深度估计方法往往不能直接应用于水下图像，因为水下环境具有独特的成像特性和场景几何特征。例如，陆地数据集中深度分布近似线性，而水下由于光衰减效应，颜色梯度变化显著，深度分布呈现非线性，固定的深度区间划分策略会引入较大误差。

基于光学的深度估计方法中，立体视觉使用两个摄像头通过视差计算深度，在许

多场景中表现良好，但在水下环境中面临空间、成本、重量限制以及标定困难等挑战。相比之下，单目深度估计仅依赖单个摄像头，具有更轻量化和成本效益的优势，成为水下条件下的更实用选择。然而，这种方法由于缺乏来自单张图像的深度线索而更具挑战性，这促使研究者不断提高水下环境中的单目深度估计技术。自监督和无监督方法为此提供了另一种思路，它们不依赖难以获取的真实深度标签。Garg 等人^[16]和 Godard 等人^[17]利用校正后的立体图像对，通过左右视图的光度一致性损失进行训练。Zhou 等人^[18]则利用单目视频序列，通过估计帧间相机运动来构建自监督信号。为了应对尺度模糊和动态场景，Wang 等人^[19]和 Ranjan 等人^[20]提出了联合学习深度、姿态、光流等多任务的框架。

近年来，这一主题因在海洋应用中的重要性而受到显著关注。Ebner 等人通过融合稀疏深度测量值，显著提高了水下机器人实时深度预测的精度，并有效解决了尺度模糊问题^[21]。Hu 等人^[22]拓展了 AdaBins 和 UDepth 的工作，通过稀疏深度先验的方法提高了预测准确性。ZoeDepth^[23]和 DepthAnything^[24]等最新模型通过结合大规模预训练的泛化相对深度模型与度量深度微调，在跨域的场景中表现较好，为水下深度估计提供了新的技术路径。

1.2.2 多传感器融合

单目视觉系统因其固有的尺度模糊性，难以独立恢复场景的绝对深度信息，这极大限制了其在自主水下航行器精确导航与避障中的应用。为解决这一根本问题，采用多传感器融合技术，协同利用不同物理特性的感知模态，已成为提升水下环境感知鲁棒性与准确性的关键研究方向。当前，为单目视觉提供尺度约束的辅助传感器主要包括激光雷达、惯性测量单元以及声呐。激光雷达可提供精确的三维点云数据，在陆地环境中，其与视觉的融合技术已相对成熟，通过将稀疏点云深度信息编码并融入卷积神经网络，有效提升了深度估计的几何精度^[25]。惯性测量单元通过感知运动加速度与角速度，可与视觉构成紧耦合系统，增强运动估计的稳定性并提供尺度参考，常用于视觉惯性里程计等任务^[26]。然而，上述传感器在水下环境中均存在明显局限：激光束在水中衰减迅速，有效探测距离严重受限；惯性测量单元在复杂水流扰动下误差累积显著，且无法直接提供深度观测。

因此，声学传感器成为水下环境中不可或缺的感知手段。其中，单波束回声测深仪因其成本低廉、功耗较小、易于集成等特点，尤其适合搭载于轻量化自主水下航行器平台。然而，单波束回声测深仪仅提供极为稀疏的深度点，且数据易受噪声干扰；多波束成像声呐虽能获取更高分辨率的二维深度信息，但其设备成本高、体积功耗大，难以在低成本平台上广泛应用。因此，本研究聚焦于单目相机与单波束回声测深仪这一特定传感器组合，其核心研究问题在于如何实现稀疏、绝对度量但含噪的一维深度

测量与稠密、相对但信息丰富的二维视觉信号之间的有效融合，从而获得分辨率更高且尺度一致的稠密深度图。

多传感器融合依其层次可分为数据级、特征级与决策级融合。数据级融合对原始数据直接进行整合，但对传感器的时空配准要求极高；特征级融合则在各自特征提取后，于特征空间实现跨模态信息交互，是目前主流且灵活的融合范式；决策级融合则对各传感器独立输出的结果进行综合，难以实现深层次的互补增强。在视觉与稀疏深度融合方面，现有研究多采用特征引导机制，例如将稀疏深度转换为注意力权重图，以增强网络对可靠深度区域的关注，进而提升整体估计精度^[27]。这些方法为水下视觉与声学信息的融合提供了一定参考。尽管如此，水下视觉与稀疏声呐数据的融合仍面临诸多特殊挑战。首先，传感器时空对准困难：声呐测量频率低，与相机帧率难以同步，且坐标系差异显著，需进行精确的时空标定。其次，数据模态差异大：图像为稠密二维矩阵，蕴含丰富纹理与语义；单波束回声测深仪输出为一维离散深度点，二者在数据结构与信息密度上存在巨大差异。最后，水下环境干扰复杂：光学图像受水体吸收与散射影响，存在颜色失真与能见度下降；声呐信号易受温度、盐度剖面及多径效应干扰，导致测量值存在不确定性。这些因素均对融合算法的稳健性提出了更高要求。

针对水下环境，现有融合方法多集中于光学图像与二维声学图像的结合，通常依赖于多波束声呐等昂贵设备^[28]。而对于单波束回声测深仪这类稀疏深度传感器，相关研究尚不充分，现有方法多将其作为后期优化中的地面控制点，用于校正视觉重建结果的尺度，或仅将其作为训练损失中的稀疏监督信号^[21]。这些方式未能充分发挥稀疏深度数据在前向推理过程中的实时引导作用，缺乏在特征层面的深度融合机制。

综上所述，当前研究在面向轻量化水下平台的实时深度感知方面仍存在不足：尚未建立一种能够有效融合异步单目视频与稀疏单波束回声测深仪数据的端到端神经网络架构，难以实现特征级的紧耦合与尺度信息的在线传递。为此，本文旨在探索一种新颖的特征融合方法，将稀疏声学深度动态编码为与视觉特征空间对齐的引导信息，通过设计跨模态交互机制，实现绝对深度先验对视觉相对深度估计的实时校正与增强，从而为自主水下航行器提供准确、鲁棒且高效的稠密深度感知能力，为后续的态势理解与自主避障奠定基础。

1.2.3 水下态势感知

态势感知 (Situation Awareness, SA) 作为一个跨领域的研究方向，在自动化与机器人领域已取得显著进展。早在 20 世纪 80 年代末，Jerome Azarewicz 等人提出了基于模板的态势评估方法^[29]，开启了该领域的研究。此后，态势感知逐步从传统的人机协作支持系统向更高层次的自动化演进。20 世纪 90 年代，Endsley 提出了著名的三阶

段模型，将态势感知定义为对环境要素的感知、对当前状况的理解以及对未来状态的预测，该模型为此后的研究奠定了重要基础^[30]。进入 21 世纪，随着科技的进步，态势感知研究逐渐从人机协作系统拓展至全自主系统。Murphy 等人首次将态势感知系统性地引入机器人领域，提出利用传感器融合技术提升环境建模精度，以支持自主决策^[31]。随着传感器技术与数据处理能力的持续发展，研究重点转向如何将大规模数据的实时处理与决策框架有机融合。Morales 等人利用贝叶斯方法对态势信息进行建模与检测，并成功应用于飞行器状态评估^[32]。Munir 等人的工作构建了一个综合性框架，不仅深化了对态势感知机理的理解，还特别强调了在动态复杂环境中提升 SA 能力的重要性^[33]。此外，Massimi 等人通过深度学习方法显著提升了空间态势感知中的目标检测与分类能力，从而增强了卫星网络应对空间碎片威胁的韧性^[34]。

近年来，水下机器人领域的态势感知研究也取得了重要进展。Ferri 等人提出了一种基于协作自主机器人网络的海上态势感知系统，展示了数据融合与协同自主如何提升复杂机器人系统在真实环境中的性能^[35]。Jeong 等人发布了首个公开的多模态传感数据集，专门用于支持自主水面航行中的水下障碍物检测研究^[36]。这些研究不仅加深了对水下环境特性的理解，也为发展更先进的水下机器人系统提供了宝贵的数据资源与方法论支撑。尽管态势感知研究已取得长足进步，但在传感器配置受限的低成本水下机器人平台上，实现可靠、精确的态势感知仍面临严峻挑战。为此，本研究旨在探索一种新的水下态势感知方法，通过融合单目相机与低成本单波束测深仪（SBES）的数据，以期在资源受限条件下提升水下机器人的环境感知与深度估计能力，推动其在实际应用中的普及与发展。

具体到水下环境，当前的态势感知方法，主要就是靠各类传感器来获取数据，再把这些数据融合起来分析。如果按传感器类型来分的话，可以分成两大类：一类是基于非视觉传感器的，另一类是基于视觉传感器的。

基于非视觉传感器的水下态势感知主要利用声呐、多普勒计程仪（DVL）、惯性导航系统（INS）、压力传感器、化学传感器等设备获取环境信息。这类方法通过多源数据融合，构建水下环境的物理或语义模型，以支持航行器的定位、避障与任务规划。例如，Horgan 等人^[37]提出了一种集成 DVL、罗经、深度传感器和高设计传感器的多传感器实时导航系统，充分利用了传感器间的互补性。Miguelanez 等人^[38]构建了一个基于语义知识的层次分布式框架，增强了自主水下系统对环境信息的感知与理解能力。Yin 等人^[39]则为 AUV 设计了一个态势推理模块，这个模块的作用，就是明确当前的态势、所需采取的行动，以及任务中可能存在的风险。Salam 等人^[40]通过在线计算环境中的相干特征集，就能为机器人提供一个实时的环境特征生成器；这样一来，机器人在类流环境中的决策能力也能得到提升。

尽管非视觉传感器在深水或浑浊水域中具有独特优势，但其感知结果往往缺乏

丰富的语义与纹理信息，且易受水下温度、压力、盐度等物理条件变化的影响，在环境理解的直观性与灵活性方面存在局限。相比之下，视觉传感器能够提供包含丰富纹理、颜色与空间细节的高分辨率图像信息，更接近人类对环境的直观认知，因此在近年来的水下态势感知研究中受到广泛关注。基于视觉的方法通常从图像或视频序列中提取特征，实现对障碍物、地形、生物等目标的检测、识别与态势评估。例如，Rodríguez-Teiles 等人^[41]提出了一种仅使用视觉信息的反应式自主导航方法，利用改进的线性迭代聚类算法能够在能见度较低条件下稳健地完成物体的分割和分类。Drews 等人^[42]基于水下暗通道先验，利用单目摄像头计算相对深度图以估计附近障碍物，为水下航行器提供避障策略。Arain 等人^[43]则采用了一种基于单目图像学习的场景范围估计器；然后，他们用这个估计器创建了地形概率高程图，这张图主要用于路径规划与避障。然而，许多传统基于视觉的方法侧重于静态图像的分割与分析，这样一来，就忽略了场景在时间和空间上的连续性；所以机器人很难通过感知这些连续的时空变化，来做出精准的决策。因此，当前的研究趋势倾向于融合视频序列分析与深度学习技术，从时序信息中提取动态变化特征，并结合单目或多目深度估计等方法，构建能够理解三维空间布局与动态演变的综合性感知模型。

综上所述，当前水下态势感知研究仍面临一系列挑战：水下专用视觉数据集稀缺，制约了数据驱动方法的深度发展；传统方法对低层视觉特征依赖较强，难以实现高层次的环境理解与意图推断；动态环境下时空连续性的有效建模尚未完善；多源异质信息的高效融合与实时决策系统的构建仍需进一步优化。因此，构建能够自适应融合多模态特征、具备时空推理与预测能力的综合性水下态势感知框架，是突破现有瓶颈、提升水下机器人自主性与适应性的关键方向，也是本研究的核心出发点。

在态势感知领域，^[44]进行了相关研究。针对 AUV 的复杂环境感知，本文提出了一种结合视觉信息和 SBES 数据的态势感知架构。该模型以单目相机捕获的视频流和 SBES 提供的声呐深度信息作为输入，经过融合处理后生成像素级的环境安全评估图像，评估结果包含“危险”、“警告”和“安全”三个安全级别，从而为 AUV 导航和决策提供更直观可靠的参考。在航空环境中，^[45]提出了一种基于卷积神经网络的语义分割方法，以帮助无人机（UAV）在执行任务时实现态势感知。类似地，水下环境中的语义分割已被广泛用于增强水下机器人的视觉引导能力^[46-48]。基于上述研究，本文采用语义分割对安全级别进行分类，为水下场景提供精细化的态势感知和导航支持。

1.2.4 水下避障算法

自主水下航行器的避障方法主要分为基于地图和无地图两种类型^[49]。如果提供了先验地图或可以构建合成地图，通常会使用路径规划方法（如 A* 或 D* 算法）在全局范围内寻找无碰撞路径，然后应用路径跟踪算法确保车辆遵循设计的路径。然而，

在真实水下环境中，特别是在非结构化或浅水区，事先获取精细和准确的地图往往不切实际。因此，大多数 AUV 依赖反应式控制策略进行避障，这些策略在不参考全局地图的情况下运行^[50]。

反应式控制方法依赖实时传感器感知做出即时决策。两种代表性方法是包容架构^[50]和人工势场法^[51]。前者实现简单，但局部操作且缺乏稳定性；后者易受动态噪声影响，并可能陷入局部最小值^[51]。为了克服这些限制，最近的研究探索了数据驱动的控制方法，如模仿学习和强化学习。尽管在仿真环境中取得了显著进展，但由于跨领域差距，在复杂的真实水下场景中部署这些方法仍然具有挑战性^[52]。

模型预测控制在机器人学中广泛应用于涉及非线性动力学和复杂约束的任务，如四旋翼和仿人机器人控制^[53,54]。传统 MPC 依赖准确的系统动力学模型来预测未来状态并优化控制动作^[52,55]。例如，Falcone 等人^[56]提出了一种基于 MPC 的方法来控制自动驾驶车辆的主动前轮转向系统。然而，传统 MPC 主要关注内部系统建模，没有明确考虑环境因素。随着在非结构化环境中操作需求的增长，需要将态势感知集成到控制回路中。为了应对这一限制，基于学习的 MPC 被引入^[57]。Qi 等人^[57]应用基于学习的 MPC 实现高速公路出口匝道分流的自主运动规划。Katara 等人^[58]提出了深度模型预测视觉伺服框架，能够实现与最优轨迹的精确对齐，并能够泛化到新环境。受这些工作的启发，本研究将基于 SA 的 MPC 框架应用于轻量化 AUV 的避障，其中 SA 预测作为主要优化约束，而系统动力学模型是一个学习的概率网络^[59]。

传统避障方法面临的主要挑战包括：对精确环境模型的依赖、缺乏对动态障碍物的适应性以及感知与控制回路之间的分离^[60]。相比之下，基于学习的方法，特别是强化学习和模仿学习，通过直接从经验中学习自适应控制策略，减少了对显式建模和高保真感知的依赖^[61]。然而，收集足够多样化的水下数据极其困难，并且学到的策略在转移到真实条件时往往泛化能力差^[62]。因此，仍然迫切需要一种在不确定感知和动态条件下能够稳健操作的高度自适应和灵活的算法^[63]。

1.3 本文的研究内容以及章节安排

本文以轻量化自主水下航行器在复杂未知水域中的高可靠自主避障为研究目标，围绕“精确几何感知-高级态势理解-智能避障决策”这一技术主线展开系统性研究。针对当前 AUV 在水下环境感知、理解与控制中存在的 key 问题，本文共分为六章，结构安排如下：第一章阐述发展海洋经济与建设海洋强国的国家战略背景，指出轻量化自主水下航行器是实现该战略的关键装备。系统分析 AUV 在水下自主作业时面临的感知与决策挑战，综述水下深度估计、多传感器融合、态势感知及避障控制等关键技术的研究现状与发展趋势，指出现有方法的局限性，进而提出本文的研究目标、意义与具体内容。

第二章介绍本文研究依托的相关工作及系统设计,说明数据来源和水下数据特征,介绍单波束回声测深仪等核心传感器的工作原理。阐述本文涉及的核心理论与方法基础,包括多传感器融合及深度估计理论、态势评估准则以及水下航行器避障控制理论。最后给出本文“感知—理解—决策—控制”一体化的水下环境感知与避障系统总体架构,明确各模块间的逻辑关系与数据流。

第三章旨在解决轻量化平台上的度量深度感知问题,详细阐述所提出的多模态深度估计网络模型。该模型包括面向水下图像的特征编码网络、针对稀疏异步单波束回声测深仪数据的预处理,以及将二者进行有效融合以恢复绝对尺度的网络结构设计。通过设计特定的融合策略,实现稀疏但度量绝对的深度测量值对稠密相对深度估计的引导。最后,在公开数据集及自采数据上进行实验,验证所提算法在恢复尺度准确、边界清晰的稠密深度图方面的优势。

第四章在第三章的基础上,将几何感知提升到语义理解层面,实现水下态势感知。详细阐述融合时空语义的态势感知模型,包括提取时序运动与空间上下文特征的多尺度时空编码网络、基于语义分割的安全等级评估模块,以及融合深度信息与视觉特征并输出像素级态势图的决策网络。在包含静态障碍、动态目标等不同复杂度的水下场景中测试,验证模型对环境风险的精细化评估能力。

第五章将前两章获得的深度感知与态势理解转化为自主航行行为,构建融合实时态势感知的模型预测控制避障框架。介绍适用于本研究 AUV 平台的简化数据驱动动力学建模方法。重点阐述如何将第四章输出的动态态势图实时转化为 MPC 优化问题中的约束或代价项,把语义化的环境认知嵌入控制回路。描述考虑平台动力学约束与态势约束的 MPC 问题构建及滚动优化求解过程。通过数值仿真与平台测试,验证该框架在动态复杂环境中实现预见性、平滑避障的有效性。

第六章是总结与展望。这一章先全面梳理了论文的研究工作与创新点。然后,客观分析了当前研究存在的局限性。最后,对未来的研究方向与应用前景做了展望。

1.4 本章小结

本章作为全文的绪论,首先从国家海洋战略需求和海洋经济发展的高度,阐明了发展智能、自主、轻量化水下航行器的重要意义,并深入剖析了水下复杂环境对 AUV 感知、理解与决策能力提出的独特挑战,特别是高精度深度估计与高层次态势理解这一核心问题。接着,通过系统梳理国内外研究现状,对水下深度估计、多传感器融合、水下态势感知及避障算法等关键技术方向的研究进展进行了全面综述与深入评析,指出了现有方法在应用于低成本、轻量化 AUV 平台时存在的局限性,为本文研究工作的展开明确了切入点与创新方向。最后,基于上述分析,概括性地提出了本文旨在解决的核心科学问题与主要研究内容,即构建一套从“多传感器紧耦合深度估计”到“时

空语义态势理解”再到”风险预见性模型预测控制”的完整技术链条，并给出了全文五章内容的组织结构安排，这部分内容为后续章节的展开，奠定了坚实的理论基础也提供了一个清晰的逻辑框架。

2 相关工作技术

2.1 水下数据收集

高质量、多样化的数据集是开展水下感知算法研究与验证的基石。考虑到水下环境复杂多变、真实数据获取成本高昂且难以精确标注的现实挑战，本研究针对深度估计与态势感知两个核心任务，分别采用了多个具有代表性的数据集。这些数据集涵盖了从浅水到深水、从清澈到浑浊、从静态到动态的多种水下环境条件，为算法的训练、验证和性能评估提供了全面而可靠的数据支撑。本节将详细阐述各数据集的来源、构建过程、处理流程以及它们在水下感知研究中的具体应用价值，展示本研究在数据构建与利用方面的系统性和严谨性。

2.1.1 数据来源

本研究根据不同的研究任务需求，采用了三类主要的数据集：用于深度估计任务的公开数据集 FLSea VI^[64] 和 Sea-thru^[65]，以及用于深度估计算法在真实传感器配置下验证的自建数据集；用于态势感知任务的自建视频数据集 UVSA。这些数据集在规模、质量和应用场景上形成了良好的互补关系，共同构成了一个全面、多层次的水下感知数据基础。

在深度估计任务方面，由于目前缺乏大规模公开可用的、专门针对声学与视觉融合深度估计任务的数据集，本研究对现有的两个高质量公开水下数据集进行了定制化改造与增强。第一个数据集是 FLSea VI，这是一个综合性水下感知数据集，如图2-1所示。这些数据是通过相机与惯性测量单元联合采集的，一共得到 22451 帧水下图像。具体来说，这些图像涵盖了 12 种真实的复杂水下场景，详细情况可以看表2-1。这些场景的水下能见度和光照条件都不太一样；里面既有珊瑚礁、岩石峡谷这样的自然地貌，也有水下管道、沉船这类人造物体。为了把这些数据更好地用在本研究的深度估计任务上，我们对数据做了一些系统性的转换和增强。首先，我们利用数据里提供的相机内参、惯性测量单元数据，还有通过运动恢复结构技术生成的高精度深度真值，构建了严格的“图像-深度”对应关系；其次，针对原始数据集中可能存在的噪声和异常值，进行了数据清洗和验证；最后，根据本研究的传感器配置（单目相机 + 单波束回声测深仪），对数据格式和坐标系统一进行了标准化处理，确保数据能够直接输入到我们的深度估计网络中。经过定制化处理后，FLSea VI 数据集成为了本研究深度估计任务的主要训练和验证基础数据集之一。




图 2-1 FLSeas VI 数据集。第一行图像为原图，第二行图像为对应的深度图

Fig. 2-1 FLSeas VI dataset. The first row of images is the original image, and the second row of images is the corresponding depth map

表 2-1 FLSeas VI 数据集场景与深度分布统计

Table. 2-1 Statistics of scene categories and depth distribution in the FLSeas VI dataset

场景	深度区间 (m)	数据集名称	图片数量 (张)
Canyons	0–12	U Canyon	2895
		Flatiron	2475
		Horse Canyon	2230
		Tiny Canyon	1012
Red Sea	0–30	Northeast Path	2593
		Landward Path	1204
		Dice Path	1428
		Pier Path	1695
		Coral Table Loop	1017
		Cross Pyramid Loop	1652
		Big Dice Loop	3159
		Sub Pier	1091
总计			22451

第二个深度估计数据集是 Sea-thru，如图2-2 所示。这个数据集的原始目标，是用物理模型去除水下图像里的散射效应。它一共包含 1205 张经过去散射处理的水下图像，还附带了对应的深度真值信息。具体细节可以看表 2-2。Sea-thru 数据集有个独特价值：里面的图像已经用专业的去散射算法处理过了。这样一来，图像的清晰度和可用信息量都得到了明显提升。不过，这个数据集的原始数据格式和任务目标，跟我们研究的方向并不完全一致。为此，我们对其进行了针对性的调整：一方面，保留了

其高质量的去散射图像和对应的深度真值，将其作为研究算法在优化后图像上性能的重要基准；另一方面，我们模拟了单波束回声测深仪的采样过程，从密集深度真值图中生成稀疏的深度点，以模拟真实传感器数据。这种处理使得 Sea-thru 数据集不仅能够用于验证深度估计网络在清晰图像上的性能，还能用于研究稀疏深度先验对网络性能的影响。通过这种方式，Sea-thru 数据集与本研究的核心问题——融合稀疏声学深度与稠密视觉信息——形成了良好的对接。




图 2-2 Sea-thru 数据集。第一行图像为原图，第二行图像为对应的深度图

Fig. 2-2 Sea-thru dataset. The first row of images is the original image, and the second row of images is the corresponding depth map

表 2-2 Sea-thru 数据集场景与深度分布统计

Table. 2-2 Statistics of scene categories and depth distribution in the Sea-thru dataset

场景	深度区间 (m)	数据集名称	图片数量 (张)
reef	0–8	D1	559
reef	0–8	D2	318
reef	0–8	D3	68
canyon	0–6	D4	153
reef	0–8	D5	59
总计			1205

除了上述两个公开数据集，为了在真实传感器配置下验证深度估计算法的性能，本研究自主构建了一个小型但高精度的验证数据集，如图2-3所示。该数据集使用 Balus 公司的 UW-70 水下摄像头和 P30E 水下单波束声呐进行采集。UW-70 水下摄像头采用 1/2.8” SONY CMOS 传感器，支持 1920×1080 分辨率，能够提供高质量的水下

图像。P30E 单波束声呐则用于获取精确的距离测量数据。图2-3展示了数据采集的相关信息，包括水下拍摄图像、相机与声呐的安装布局示意图以及宏观实验场景布置。数据采集过程在可控的水下环境中进行，通过设置固定的参照物（如带有已知尺寸标记的标定板），同步获取摄像头图像和声呐测距数据。在采集过程中，我们严格控制了相机与声呐的相对位置和姿态，并通过硬件同步确保了数据的时间一致性。这一自建数据集虽然规模有限，但提供了从真实传感器获取的同步图像和声呐距离数据，为评估算法在实际传感器配置下的性能、验证传感器标定精度以及研究多模态数据融合的实际效果提供了重要支撑。




图 2-3 自建验证数据集采集装置与场景，包含水下拍摄图像、相机与声呐布局示意图以及宏观实验场景布置

Fig. 2-3 Custom-built verification dataset acquisition setup and scene, including underwater captured image, camera and sonar layout diagram, and macro experimental scene arrangement

在态势感知任务方面，当前水下研究领域面临一个显著瓶颈：缺乏公开可用的、基于视觉传感器的态势评估视频数据集。现有的研究成果大多基于非视觉传感器数据，目前还缺少一套视频数据集——既要有连续的监测画面，也能用来做精细化的安全评估。这一现状很大程度上阻碍了水下态势感知技术的研究进展。而且，构建这类

数据集本身就是个难题。最核心的问题在于，缺少一个大家都认可、又统一的态势安全评估标准。

为了突破这一瓶颈，本研究使用了自主构建了名为 UVSA (Underwater Visual Situation Awareness) 的基于视觉的水下态势评估视频数据集。该数据集的构建遵循了系统化、科学化的原则，整个过程可分为四个阶段：数据收集、筛选与预处理、标注框架设计、人工标注与质量验证。在数据收集阶段，我们从多个在线资源和专业水下摄影网站系统地搜集了水下视频资料，这些视频来源于全球不同海域、不同深度和不同环境条件，确保了数据来源的多样性和代表性。在筛选与预处理阶段，我们制定了严格的标准：优先选择具有较高分辨率（不低于 1920×1080 ）、清晰图像质量、稳定拍摄角度和充足光照条件的视频片段；对选定的视频进行格式统一、剪辑分段和帧率调整（统一为 30 帧/秒）等操作，以确保数据的规范性和可用性。经过多轮筛选和整理，最终确定了 326 个符合要求的水下视频，构成了 UVSA 数据集的核心。这些视频涵盖了珊瑚礁、沉船遗址、海底山脉、深海平原等多种典型生态系统，以及静态障碍物、动态目标、半透明障碍物等多种对水下机器人航行有实际意义的场景元素。



图 2-4 UVSA 数据集中的原始水下场景示例

Fig. 2-4 Examples of raw underwater scenes from the UVSA dataset

UVSA 数据集的部分原始场景示例如图 2-4 所示。该数据集的构建过程中，最具创新性的环节是态势评估准则和标注框架的设计。我们基于经典的 Endsley 态势感知三层次模型（感知、理解、预测），结合水下机器人自主导航的实际需求，设计了一套层次化的安全评估准则。具体而言，我们将环境区域划分为三个安全等级：“危险”（红色）表示该区域存在立即的碰撞威胁，如近距离的刚性障碍物；“警告”（黄色）表示该区域存在潜在风险，需要谨慎对待，如中距离的半透明障碍物或动态目标；“安全”（绿色）表示该区域可以安全通过。这套准则不仅考虑了障碍物的距离，还综合考虑了其类型（刚性/非刚性）、运动状态（静态/动态）以及先验知识（如特定区域出现渔网的概率），从而形成了一套全面、可操作的评估标准。基于这一准则，我们设计

了详细的标注规范。具体的态势评估准则将在第2.2.3节详细介绍。最终，每个视频帧都生成了对应的像素级态势评估图，将环境区域精确划分为“危险”、“警告”和“安全”三个等级。




图 2-5 UVSA 数据集标注示例：上方为原始水下图像，下方为对应的态势评估标注图（红色：危险，黄色：警告，绿色：安全）

Fig. 2-5 Annotation examples from the UVSA dataset: Top row shows raw underwater images, bottom row shows corresponding situation assessment maps (Red: Danger, Yellow: Warning, Green: Safe)

UVSA 数据集的标注示例如图2-5所示，其中上方为原始水下图像，下方为对应的态势评估标注图。这一精细化的标注工作为监督学习提供了高质量的监督信号，使得 UVSA 数据集成为目前水下领域首个公开可用的、具有精细化安全等级标注的视觉态势评估数据集。

2.1.2 水下数据特征

水下感知任务的核心挑战源于水下光学成像环境的极端复杂性。与陆地环境不同，水体对光线的吸收、散射效应以及多变的水下光照条件，使得通过相机捕获的图像普遍存在严重的质量退化问题。如图2-6所示，水下图像主要表现为对比度低、纹理模糊、颜色失真及光照不均匀等典型特征。这些固有缺陷对基于视觉的感知算法构成了根本性挑战：低对比度和模糊纹理削弱了特征提取与匹配的有效性；剧烈的颜色失真（通常整体偏蓝绿色）破坏了物体固有的颜色信息；由水面波纹折射和体内散射导致的光照不均匀，则会在图像中形成非真实的明暗变化，极易误导深度估计等视觉任务。

具体而言，水下图像的退化特性主要源于以下几个物理因素：光反射会在水面或光滑物体表面形成强烈的高光或光斑，这些区域的亮度信息与物体的真实几何形状无关，严重干扰了深度估计网络对表面法线和距离的判断；光衰减导致光线随传播距离

呈指数衰减，使远处物体在图像中对比度急剧下降、细节模糊，极大限制了视觉感知的有效范围；浑浊度则因水中悬浮颗粒造成的散射效应，使图像呈现雾状外观，整体对比度降低，物体边缘模糊。这些物理因素的综合作用，使得单纯依赖光学图像的感知系统在水下环境中面临严峻挑战。这些图像退化问题进一步导致先进的视觉感知算




图 2-6 水下图像质量退化问题综合示意图。图中展示了 (a) 低对比度、(b) 颜色失真、(c) 光照不均匀、(d) 浑浊、(e) 光反射及 (f) 光衰减等多种典型水下成像问题

Fig. 2-6 Comprehensive illustration of underwater image quality degradation problems. The figure shows various typical underwater imaging issues: (a) low contrast, (b) color distortion, (c) uneven illumination, (d) turbidity, (e) light reflection, and (f) light attenuation

法在水下环境中效能显著下降。以自监督深度估计方法为例，当其直接应用于水下图像时会出现严重错误：模糊图像导致基于光度一致性的损失函数失效；多变的光照破坏了外观一致性假设；动态目标违反了静态场景假设。特别是在背景区域因散射或直射光显得异常明亮时，网络极易将远处背景错误地估计为近处前景。

面对上述挑战，单一依赖光学图像的感知范式存在根本性局限。为此，本研究提出通过融合单波束回声测深仪（SBES）提供的稀疏但绝对度量的深度信息，来减少对易退化光学图像的过度依赖。

2.2 相关技术介绍

2.2.1 单波束回声探测仪原理

单波束回声探测仪（Single-Beam Echo Sounder, SBES）是基于水声学原理实现水下测距与深度探测的核心传感器，也是本研究的核心器件之一，下面来详细介绍其

相关原理。本研究所采用的 P30e 型测距声呐（外观如图2-7 所示）由 SeaRobotix 与 BlueRobotics 联合开发，是一款高性价比的水下测距设备。该传感器采用紧凑型防水设计，尺寸为 $\Phi 60\text{mm} \times 35\text{mm}$ ，重 135g（空气中），通过 4 个 M3 $\times$ 5mm 螺栓固定于安装底座，可便捷集成于 BlueROV2 等水下机器人平台。



图 2-7 P30e 单波束回声探测仪外观图

Fig. 2-7 Appearance of P30e single-beam echo sounder

P30e 声呐的工作原理基于声波在水介质中的传播特性，其测量原理如图2-8 所示。传感器表面的换能器发出固定频率（115kHz）的声波脉冲，该脉冲以 30° 的圆锥形波束向下发射。当声波在水中传播遇到障碍物（如海底或水下物体）时，一部分声波会被吸收，另一部分声波将从障碍物反射回来。通过监听并测量回波的时间以及返回声波的强度，可以计算出设备与障碍物之间的距离。具体过程为：发射器产生声学脉冲信号，经换能器转换为机械振动并向水下发射；声波在水中以近似恒定的速度传播，当遇到海底或水下障碍物时会发生反射。接着，接收换能器会捕获这些回波信号；再通过测量发射与接收之间的时间差，就可以计算出目标的距离。

P30e 声呐硬件系统主要由发射器、接收换能器、信号调理电路和数字信号处理器组成，通过 USART-TTL 串口与上位机通信。传感器供电电压为 5.5V，功耗仅为 0.5W，适合用于低功耗自主水下航行器平台。其技术参数如表2-3 所示，测距范围 0.6-30m，在 2m 距离处测量精度可达 1cm（相对精度 0.5%），能够满足大部分近海底观测任务的精度需求。工作过程中，换能器以固定频率发射声波脉冲，脉冲宽度和发射间隔可通过软件调节，典型发射速率为 15ping/s。




图 2-8 P30e 单波束回声探测仪测量原理示意图

Fig. 2-8 Schematic diagram of P30e single-beam echo sounder measurement principle

声波在水介质中的传播遵循声学波动方程：

$$\nabla^2 p - \frac{1}{c^2} \frac{\partial^2 p}{\partial t^2} = 0 \quad (2-1)$$

其中 p 为声压， c 为声速。实际应用中，声速受水温、盐度和压力等因素影响，海水中的典型声速为 1500m/s，淡水中为 1435m/s。P30e 声呐支持声速手动设置功能，可根据实际水环境参数进行校准以提高测距精度。实际水体通常呈现分层结构，声速剖面 $c(z)$ 随深度 z 变化导致声线弯曲，其传播路径可通过射线声学模型描述：

$$\frac{d}{ds} \left(\frac{1}{c} \frac{dr}{ds} \right) = -\frac{1}{c^2} \nabla c \quad (2-2)$$

其中 s 为声线弧长， r 为位置矢量。声波强度衰减由扩展损失与吸收损失共同决定，总衰减系数 α 可表示为：

$$\alpha(f, T, S, pH) = \alpha_{\text{spreading}} + \alpha_{\text{absorption}}(f, T, S, pH) \quad (2-3)$$

其中扩展损失遵循球面波衰减规律 $\alpha_{\text{spreading}} = 20 \log_{10} R$ (R 为传播距离)，吸收损失 $\alpha_{\text{absorption}}$ 与频率 f 、水温 T 、盐度 S 、酸碱度 pH 相关，常采用 Francois-Garrison 经验模型计算。对于 P30e 声呐采用的 115kHz 工作频率，在典型海水环境中的吸收损失约为 3.5dB/m。

发射信号通常采用线性调频脉冲以提高距离分辨率和抗干扰能力：

$$s_t(t) = A_t \cos(2\pi f_0 t + \pi k t^2) \cdot \text{rect}\left(\frac{t}{T_p}\right) \quad (2-4)$$

其中 $f_0 = 115\text{kHz}$ 为中心频率， k 为调频斜率， T_p 为脉冲宽度。接收回波信号为发射信号经目标反射后的时延叠加：

$$s_r(t) = \sum_{i=1}^N \alpha_i s_t(t - \tau_i) + n(t) \quad (2-5)$$

式中 α_i 为第 i 个散射体的反射系数, $\tau_i = 2R_i/c$ 为双向传播时延, $n(t)$ 为加性噪声。P30e 声呐内置数字信号处理器, 采用匹配滤波器实现脉冲压缩以提升信噪比和距离分辨率:

$$y(\tau) = \int_{-\infty}^{\infty} s_r(t) s_t^*(t - \tau) dt \quad (2-6)$$

峰值检测通过恒虚警率检测器实现, 最终测距结果通过时延计算获得:

$$R = \frac{c \cdot \tau}{2} \quad (2-7)$$

在数据采集过程中, 本研究使用 PingViewer 软件作为上位机控制界面 (如图2-9), 该软件支持实时数据显示、参数设置、数据记录与回放等功能。软件界面中, 瀑布图以三维形式显示连续的测距样本, 颜色深度表示信号强度; 回声强度图以二维形式显示当前距离对应的回波强度。通过软件设置可调整声速参数、增益控制、扫描起始点和测量范围等关键参数, 以适应不同的水下环境需求。




图 2-9 PingViewer 软件上位机界面示意图

Fig. 2-9 Schematic diagram of the upper computer interface of PingViewer software

在实际部署中, 声呐通常以 30° 俯角向下安装, 以减少背景水体对测量的干扰。传感器输出的距离数据包含置信度信息, 以百分比形式表示测量可靠性 (0% 为红色低置信度, 50% 为黄色中等置信度, 100% 为绿色高置信度), 为后续数据处理提供质量评估依据。

表 2-3 P30e 单波束回声探测仪技术参数

参数	规格
工作频率	115 kHz
波束宽度	30°
测距范围	0.6-30 m
测距精度	0.5% (2 m 处 1 cm, 30 m 处 15 mm)
供电电压	5.5 V
功耗	0.5 W
通信接口	USART-TTL (3.3-5 V)
耐压深度	300 m
重量 (空气中/水中)	135 g / 48 g
缆线长度	1 m
工作温度	-10°C 至 40°C

2.2.2 多传感器融合及深度估计理论

单目深度估计旨在从单张二维图像中恢复场景的三维几何结构，这是一个典型的病态问题，因为三维到二维的投影过程损失了深度信息。传统方法依赖手工设计的特征和几何先验，但在复杂水下环境中泛化能力有限。近年来，深度学习通过从大规模数据中学习图像特征与深度间的复杂映射关系 $f: I \rightarrow D$ ，显著提升了深度估计的性能^[66]。然而，纯视觉方法存在固有的尺度模糊问题，无法恢复度量准确的绝对深度，这限制了其在自主水下航行器 (AUV) 等需要精确导航的机器人应用中的实用性。

为解决这一问题，多传感器融合技术被广泛研究，其核心思想是通过协同利用不同物理原理、具有互补特性的传感器，构建比单一传感器更完备、更可靠的环境感知模型。多传感器融合的主要方法包括贝叶斯推理^[67]、聚类分析^[68]、卡尔曼滤波^[69]及深度学习方法^[70]。

1. 贝叶斯推理 贝叶斯推理基于概率论，通过联合后验概率分布实现多源数据融合：

$$P(X|Z_1, Z_2, \dots, Z_n) \propto P(X) \prod_{i=1}^n P(Z_i|X) \quad (2-1)$$

其中， X 为状态估计， Z_i 为第 i 个传感器的观测数据。

2. 聚类分析 聚类分析通过一致性度量实现数据融合，剔除奇异点。其目标是最小

化簇内距离：

$$C = \arg \min_C \sum_{i=1}^k \sum_{x \in C_i} d(x, \mu_i) \quad (2-2)$$

其中， C 为聚类结果， $d(x, \mu_i)$ 为数据点 x 与簇中心 μ_i 的距离。

3. 卡尔曼滤波卡尔曼滤波是一种递归估计算法，适用于线性高斯系统。其递推公式包括预测与更新：

$$\hat{x}_{k|k-1} = F_k \hat{x}_{k-1|k-1} + B_k u_k \quad (2-3)$$

$$P_{k|k-1} = F_k P_{k-1|k-1} F_k^T + Q_k \quad (2-4)$$

其中， $\hat{x}_{k|k-1}$ 为状态预测值， $P_{k|k-1}$ 为预测协方差矩阵。

4. 深度学习方法深度学习方法在多模态数据融合中主要分为早融合（Early Fusion）和晚融合（Late Fusion）两种框架。早融合方法在早期阶段直接将稀疏深度图与 RGB 图像进行特征串联，而晚融合方法在网络的中间层进行特征融合。

晚融合方法是目前主流的方法，其核心思想是在网络的中间层进行特征融合。晚融合模型通常包含两个子网络：(1) RGB 特征提取子网络：从 RGB 图像中提取高层次语义特征；(2) 深度特征提取子网络：从稀疏深度图中提取几何特征。

晚融合过程通常在两个子网络的中间层进行，通过结合 RGB 图像的语义信息和深度图的几何信息，提升模型的性能。晚融合方法可分为三类：

双编码器网络：例如，Zhang 等人^[71]提出了多尺度自适应融合网络（MAFN）。MAFN 的主要贡献是自适应融合模块（Adaptive Fusion Module, AFM），它将从 RGB 和深度模态中提取的特征融合并传递给近邻注意力模块，以增强其局部近邻关系信息。其网络结构如图2-10 所示。




图 2-10 晚融合-双编码器网络结构示意图

Fig. 2-10 Structure diagram of late fusion dual-encoder network .

双编码器-解码器网络：GuideNet^[72]是一个双编码器-解码器网络，其中引导卷积从 RGB 特征中学习融合核，并将其应用于深度特征。该网络结构如图2-11 所示。




图 2-11 晚融合-双编码器-解码器网络结构示意图

Fig. 2-11 Structure diagram of late fusion dual encoder-decoder network.

全局和局部深度预测：AdaBins^[15] 提出计算根据输入场景的特征动态变化的自适应容器，将分类的优点与深度图回归的优点结合起来。其网络结构如图2-12 所示。




图 2-12 全局和局部深度预测网络结构示意图

Fig. 2-12 Structure diagram of global and local depth prediction network.

对于水下深度估计任务，Liu 等人^[73] 提出了一种创新的融合方案，将单目相机与低成本单波束回声测深仪 (SBES) 相结合。SBES 通过发射声脉冲并测量回波时间来计算单个距离值，提供了稀疏但绝对度量的深度信息，为单目深度估计提供了尺度基准。

针对“单目相机 + SBES”的配置，融合的核心挑战在于如何将稠密但尺度模糊的视觉特征 F_v 与稀疏但绝对度量的声学测量 F_s 有效结合。Liu 等人^[73] 提出了一种创新的掩膜表示方法，通过将 SBES 的单个距离读数转换为与图像空间对齐的掩膜图，实现了更有效的特征融合。具体而言，该方法首先根据 SBES 的声锥模型和相机标定参数，将测量点投影到图像平面上，形成一个候选区域；然后通过图像分割技术（如基于高斯混合模型的聚类算法）排除背景区域，最终生成一个与图像尺寸相同的掩膜 M_t ，其中候选区域内像素赋值为 SBES 测量值，其余区域为零值（表示未知）。这一掩膜表示相较于原始的单点测量，提供了更密集的空间引导信息。

在神经网络架构设计上，参考文献^[73] 采用了一种双编码器结构，分别处理单目图像 I_t 和 SBES 掩膜 M_t 。两个编码器基于 ResNet-18 构建，独立提取各自模态的特征（如图2-13 所示）。随后，在解码器阶段通过中间融合策略，逐步整合多尺度多模态特

征，最终预测出稠密的深度图 D_t 。这种设计使得网络能够同时利用视觉线索的丰富性和声学测量的绝对尺度信息。训练过程采用自监督范式，通过构建光度重建损失函数 L_p 和边缘感知平滑损失函数 L_s 来优化网络参数^[66]。光度损失利用相邻帧间的几何一致性约束，鼓励网络预测出符合多视图几何的深度；平滑损失则通过考虑图像梯度，在物体边缘处保持深度不连续性的同时，在纹理均匀区域施加平滑约束。整个训练过程无需真实的稠密深度标注，特别适合标注数据稀缺的水下场景。




图 2-13 Liu 等人提出的 SBES 与图像特征融合双编码器网络结构

Fig. 2-13 Dual-encoder network architecture for SBES and image feature fusion proposed by Liu et al.

为进一步利用 SBES 提供的绝对度量信息，Liu 等人^[73]还探索了将 SBES 测量值直接作为监督信号的方法，在自监督损失基础上增加了一个基于 SBES 测量的 L1 损失项 L_b ，强制网络在 SBES 测量点处的预测深度与实际测量值一致，从而辅助网络学习绝对尺度。这种融合策略使得最终的网路能够生成尺度统一、度量准确的稠密深度图，为水下机器人的自主导航提供了可靠的感知支撑^[74]。

2.2.3 态势评估准则理论

态势感知源于人因工程与军事指挥领域，在自动化系统中指对环境信息进行整合、理解并预测未来状态以支持决策的能力^[30]。经典的 Endsley 模型将其分为三个层次：感知环境元素、理解整体局势、预测发展趋势（如图2-14所示）。在水下避障中，需将原始感知信息转化为航行安全的语义信息，这依赖于合理的态势评估准则。

传统方法将水下环境简单分为“危险”与“安全”两类，忽略了障碍物多样性与环境复杂性。本文提出更细致的三分法：“危险”、“警告”和“安全”区域。依据水下物体的移动性与物理特性，建立如表2-4所示的评估准则。危险区域包括静态刚性物体（岩石、沉船）和动态非刚性物体（摆动海藻）；警告区域包括静态非刚性物体（沙石）和动态非刚性物体的运动范围；安全区域则为无生物或动态刚性物体（鱼类）所在区域。




图 2-14 Endsley 态势感知模型

Fig. 2-14 Endsley Situation awareness model.

表 2-4 态势评估准则表

Table. 2-4 Situation assessment criteria table

区域特性	危险区域	警告区域	安全区域
静态刚性物体	√		
动态非刚性物体	√		
静态非刚性物体		√	
动态非刚性物体运动区域		√	
动态刚性物体			√
无生物存在			√

为训练态势评估模型，需对水下图像进行标注。标注时忽略不构成威胁的游动生物（如海龟、鱼类），依据障碍物存在性、相对距离与图像复杂度将图像区域划分为三类（标注标准见表2-5）。从数据集中选取 1630 张图像，进行像素级标注，生成态势评估图（如图2-5）。

表 2-5 水下环境区域类型评估与标注标准

Table. 2-5 Underwater environment area type evaluation and annotation standards

区域类型	障碍物存在	相对距离	图像复杂度	标注颜色
危险区域	存在	近	非常高	红色
警告区域	存在	较近	高	黄色
安全区域	不存在	远	低	绿色

2.2.4 水下航行器避障控制理论

自主水下航行器（AUV）的避障控制是一个涉及环境感知、动态建模、路径规划与控制执行的综合问题。由于水下环境的复杂性与不确定性，传统的地面机器人避障方法难以直接应用。本节将系统阐述水下航行器避障控制的主要理论与方法，重点介绍模型预测控制（MPC）及其与其他避障算法的对比。

根据环境先验信息的可用性，水下避障方法可分为基于地图的全局路径规划方法以及无地图的反应式避障方法两大类。当存在先验环境地图或可实时构建地图时，AUV 可采用全局路径规划算法生成最优无碰撞路径。其中，A* 算法^[75]是最经典的启发式搜索算法之一，它通过评估函数 $f(n) = g(n) + h(n)$ 寻找从起点到目标点的最短路径，其中 $g(n)$ 表示从起点到节点 n 的实际代价， $h(n)$ 为从节点 n 到目标点的启发式估计代价。A* 算法在水下静态结构化环境中表现良好，能够保证找到最优解，但难以应对动态变化的障碍物环境。D* 算法（Dynamic A*）^[76]是专门为动态环境设计的增量式搜索算法，它能够在环境发生变化时高效地重新规划路径，适用于未知或部分已知的复杂水下环境。快速随机树（Rapidly-exploring Random Tree, RRT）系列算法^[77]通过随机采样方式在构型空间中构建搜索树，适用于高维空间和非完整约束系统，但其生成的路径通常不够平滑，需要进行后续优化处理。这些基于地图的方法通常需要配合路径跟踪控制器（如 PID 控制^[78]、滑模控制^[79]等）来执行规划好的路径，但在动态复杂的真实水下环境中，高精度全局地图的实时获取与更新往往难以实现，从而限制了这类方法的实际应用效果。

在无先验地图或环境高度动态的场景中，反应式避障方法基于实时传感器数据做出局部避障决策。其中，人工势场法^[80]将目标点建模为引力源，将障碍物建模为斥力源，通过势场梯度产生的虚拟力引导 AUV 运动。其控制律可表示为：

$$\mathbf{F}_{\text{total}} = \mathbf{F}_{\text{att}} + \sum \mathbf{F}_{\text{rep}} \quad (2-8)$$

其中 $\mathbf{F}_{\text{att}} = -k_{\text{att}} \nabla d_{\text{goal}}$ 表示吸引力，与 AUV 到目标点的距离 d_{goal} 的梯度成正比； $\mathbf{F}_{\text{rep}} = k_{\text{rep}} \left(\frac{1}{d_{\text{obs}}} - \frac{1}{d_{\text{safe}}} \right) \nabla d_{\text{obs}}$ 表示排斥力，当 AUV 与障碍物的距离 d_{obs} 小于安全距离 d_{safe} 时产生斥力。该方法计算简单、响应快速，但容易陷入局部极小值，且在复杂障碍物环境中可能产生震荡现象。子控制架构是一种基于行为的分层控制策略，将避障、巡航、目标跟踪等基本行为模块并行执行，通过预设的优先级仲裁机制选择最终控制指令。该方法实现简单、鲁棒性强，但各行为模块之间缺乏协同优化，可能导致系统行为冲突和效率低下。模糊逻辑控制则基于专家经验构建模糊规则库，通过模糊化、模糊推理和解模糊化三个步骤将传感器信息映射为控制指令。这种方法能够有效处理水下环境中的不确定性和非线性问题，但模糊规则的设计和优化高度依赖专家经验，且随着系统复杂度的增加，规则库可能变得难以维护。模型预测控制^[81]是一种

基于滚动优化与反馈校正的先进控制策略，特别适用于具有约束的多变量系统。其核心思想是在每个控制周期内，基于当前系统状态，求解有限时域内的最优控制序列，并仅执行序列中的第一步控制量，然后在下一个周期重新进行优化。标准 MPC 问题的数学表述如下：

$$\begin{aligned} \min_{\mathbf{U}} \quad & J = \sum_{k=0}^{H-1} \left(\|\mathbf{x}_{t+k|t} - \mathbf{x}_{\text{ref}}\|_{\mathbf{Q}}^2 + \|\mathbf{u}_{t+k}\|_{\mathbf{R}}^2 \right) \\ \text{s.t.} \quad & \mathbf{x}_{t+k+1|t} = f(\mathbf{x}_{t+k|t}, \mathbf{u}_{t+k}) \end{aligned} \quad (2-9)$$

$$\mathbf{x}_{\min} \leq \mathbf{x}_{t+k|t} \leq \mathbf{x}_{\max}$$

$$\mathbf{u}_{\min} \leq \mathbf{u}_{t+k} \leq \mathbf{u}_{\max}$$

其中 H 为预测时域， $\mathbf{x}_{t+k|t}$ 表示在 t 时刻预测的 $t+k$ 时刻系统状态， $\mathbf{u}_{t+k}$ 为控制输入， $\mathbf{Q}$ 和 $\mathbf{R}$ 分别为状态和控制输入的权重矩阵， $f(\cdot)$ 为描述系统动态特性的数学模型。

传统 MPC 方法依赖于精确的系统机理模型，而在复杂水下环境中，AUV 的动力学模型往往难以准确建立。为此，学习型 MPC^[82] 通过数据驱动方法构建系统动态的近似模型：

$$\mathbf{x}_{t+1} = f_{\theta}(\mathbf{x}_t, \mathbf{u}_t) + \omega_t \quad (2-10)$$

其中 f_{θ} 为神经网络等参数化模型， ω_t 为过程噪声。在视觉伺服领域，深度模型预测控制（Deep MPC）^[58] 利用光流等中间视觉表示，通过神经网络预测未来状态并在线优化控制序列，能够在未知环境中实现精确的视觉伺服控制。如图2-15所示，该方法通过光流网络编码当前与目标图像间的差异，并利用控制网络在线生成最优控制指令，为水下环境中的模型预测控制提供了重要参考。




图 2-15 深度模型预测视觉伺服控制框架示意图

Fig. 2-15 Deep model predictive visual servoing control framework schematic diagram

基于 Deep MPC 的思路，本文提出的 SA-MPC 框架将态势感知信息深度融入 MPC 优化过程，以适应水下复杂环境。在 SA-MPC 框架中，采用概率多层感知机 (Probabilistic MLP) 网络同时输出状态预测的均值 μ_{t+1} 与方差 σ_{t+1}^2 ，以表征模型预测的不确定性：

$$[\mu_{t+1}, \log \sigma_{t+1}^2] = f_{\theta}(\mathbf{x}_t, \mathbf{u}_t) \quad (2-11)$$

该模型通过最小化负对数似然损失函数进行训练：

$$\mathcal{L}_{\text{NLL}}(\theta) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^{n_x} \left[\frac{(x_{t+1,j}^{(i)} - \mu_{t+1,j}^{(i)})^2}{\sigma_{t+1,j}^{2(i)}} + \log \sigma_{t+1,j}^{2(i)} \right] \quad (2-12)$$

通过定义空间风险势场 $V_{\text{risk}}(\mathbf{x}_t)$ ，将环境安全约束转化为代价函数的一部分：

$$V_{\text{risk}}(\mathbf{x}_t) = w_s \Phi_s(S_t(\mathbf{x}_t)) + w_d \Phi_d(D_t(\mathbf{x}_t)) \quad (2-13)$$

其中 $\Phi_s(\cdot)$ 函数基于态势感知模块输出的安全等级（安全、警告、危险）计算语义风险势能， $\Phi_d(\cdot)$ 函数基于深度信息惩罚 AUV 与障碍物的接近程度， w_s 和 w_d 分别为语义与几何信息的权重系数。完整的 SA-MPC 优化问题可表述为：

$$\begin{aligned} \min_{\mathbf{U}} \quad & \sum_{t=0}^{H-1} (\|\mathbf{x}_{t+1} - \mathbf{x}_{\text{goal}}\|^2 + \|\mathbf{u}_t\|^2 + V_{\text{risk}}(\mathbf{x}_{t+1}) + \eta \text{tr}(\sigma_{t+1}^2)) \\ \text{s.t.} \quad & \mathbf{x}_{t+1} = f_{\theta}(\mathbf{x}_t, \mathbf{u}_t) \end{aligned} \quad (2-14)$$

该框架实现了感知-理解-决策-控制的一体化闭环，在保障航行安全的同时，优化了轨迹平滑性与能量效率。本研究将深度模型预测控制的思想扩展至水下环境，通过融合视觉-声纳感知信息，构建了更适应水下复杂条件的深度模型预测控制架构。

2.3 水下环境感知与避障系统架构

基于前文所述的理论基础，本文提出了一套面向轻量化自主水下航行器的层次化自主避障系统总体架构。该架构遵循“感知—理解—决策—控制”的经典自主系统范式，将多模态感知、高级态势理解与实时优化控制深度融合，形成一个完整的智能闭环控制系统。系统的整体架构如图2-16所示，其核心思想是利用低成本、互补性强的传感器（单目相机与单波束回声测深仪）获取原始环境数据，通过分层递进的信息处理与决策机制，最终生成安全、高效的运动控制指令。

深度估计模块负责将单目视觉的相对深度信息与单波束回声测深仪的稀疏绝对深度测量进行融合。该模块首先通过单目深度估计网络从 RGB 图像中提取相对深度信息，然后利用 SBES 提供的稀疏绝对深度点作为引导，通过高斯扩散机制将绝对尺




图 2-16 水下态势评估与避障系统整体架构

Fig. 2-16 Overall architecture of underwater situation assessment and obstacle avoidance system

度信息自适应地传播至整个图像区域，实现视觉与声学数据的特征级融合。该模块的输出为每一帧图像对应的精确稠密深度图，为后续模块提供了可靠的三维几何环境信息。具体实现过程将在第 3 章重点分析和介绍。

态势感知模块在深度信息的基础上，融合时序图像数据实现高层次的环境语义理解与风险评估。该模块接收连续的 RGB 图像序列与深度融合模块输出的深度图，通过时空编码网络提取场景的动态演变特征与空间上下文信息。基于预先定义的态势评估准则（见表 2-4），模块对每个像素区域进行安全等级分类，输出像素级的态势评估图，将环境划分为“危险”、“警告”与“安全”三类区域。在复杂、退化的水下视觉环境中，该模块能有效识别动态和非刚性障碍物，提升了系统的环境理解能力。具体实现过程将在第 4 章重点分析和介绍。

SA-MPC 控制核心是整个系统的决策与执行中枢，以学习型 MPC 为核心，将水下航行器的动力学模型、当前状态、目标点以及态势感知模块提供的动态环境风险场统一纳入一个优化框架中。控制核心采用概率多层感知机从数据中学习航行器在扰动下的动力学特性，同时输出状态预测的均值与方差以表征不确定性。在优化目标中，除了常规的轨迹跟踪误差与控制量惩罚外，创新性地引入了由态势评估图与深度图构建的空间风险势场 V_{risk} 作为安全约束项。在每个控制周期，求解器在线滚动优化未来时域内的控制序列，并立即执行第一步的控制指令，实现平滑、节能且的避障。具体实现过程将在第 5 章重点分析和介绍。

2.4 本章小结

本章系统构建了本研究的理论基础与技术框架，从数据、理论与系统三个层面为后续工作奠定了坚实基础。通过整合多源数据集，明确了水下感知任务的挑战与数据

需求；通过对光学成像、声学测距、多模态融合、态势评估及避障控制等核心理论的梳理与阐述，为方法设计提供了原理支撑；最终，提出了一个层次化的“感知-理解-决策-控制”控制系统架构，将多模态信息深度融合与学习型 MPC 相结合，为应对水下复杂、不确定环境提供了一套完整的解决方案。本章内容构成了后续各章节算法设计与验证工作的总纲。

3 基于单波束声呐的水下单目深度估计

3.1 方法概述

准确的水下深度感知是实现自主水下航行器环境理解与安全导航的基础。然而，水下环境存在光线衰减、散射效应和颜色失真等复杂光学特性，制约了传统单目视觉深度估计方法的性能。同时，单目深度估计固有的尺度模糊问题，使其在需要精确度量信息的机器人任务中实用性受限。单波束回声测深仪（SBES）能够提供稀疏但绝对准确的深度测量，但其有限的空间分辨率难以构建满足导航需求的稠密深度图。针对上述问题，本章提出一种深度融合方法，将单目相机提供的稠密相对深度信息与 SBES 提供的稀疏绝对深度点进行融合，生成高分辨率且尺度一致的稠密深度图。

本章方法包含三个主要步骤：首先，通过单目深度估计网络从 RGB 图像中预测初始相对深度图；其次，利用几何标定后的 SBES 测量值，为相对深度图提供尺度校正；最后，通过残差高斯扩散机制，将稀疏声学测量的校正信息根据空间邻近性与深度相似性传播至整个图像区域，完成深度图的优化。该框架在提升深度估计度量精度的同时，能够有效抑制水下典型退化现象带来的干扰，为后续态势感知与决策控制模块提供可靠的几何环境表征。

3.2 传感器标定与跨模态数据配准

实现视觉与声学数据有效融合的首要步骤是建立两者之间的精确几何对应关系。本系统采用单目相机与 SBES 的异构传感器组合。为实现精确融合，需完成相机内参标定以及相机与 SBES 之间的外参标定。

首先，对单目相机进行内参标定。采用张正友标定法，利用棋盘格标定板获取相机的内参矩阵 $\mathbf{K}$ 和畸变系数。随后，进行相机与 SBES 之间的相对位姿标定（外参）。如图3-1所示，以相机光心为相机坐标系原点 O ，SBES 相对于相机的位置固定为 C 。SBES 通过记录声波往返时间计算目标距离。设波束角为 α ，回声探测器返回的距离值为 m_i ，声锥底圆半径 r_i 可表示为：

$$r_i = m_i \cdot \tan(\alpha) \quad (3-1)$$

声锥方向的单位向量（相对于相机坐标系）为 $\vec{n}$ ，声锥底面中心的三维坐标 C_i 可表示




图 3-1 SBES-相机融合系统的几何模型

Fig. 3-1 Geometric model of the SBES-camera fusion system

为：

$$C_i = m_i \cdot \vec{n} + C \quad (3-2)$$

根据 Liu 等人^[73]提出的方法，该三维点 C_i 可通过相机的针孔模型投影至图像平面。投影得到的齐次图像坐标为 $(a', b', e')^T$ ，最终像素坐标 (a, b) 通过归一化尺度因子 e' 获得：

$$\begin{bmatrix} a' \\ b' \\ e' \end{bmatrix} = K \cdot C_i, \quad a = \frac{a'}{e'}, \quad b = \frac{b'}{e'} \quad (3-3)$$

其中， (a, b) 为 SBES 测量在图像上的对应像素坐标， K 为相机的内参矩阵。由此，单个 SBES 测量值对应于图像中的一个投影区域 R ，该区域近似为以 (a, b) 为中心、半径与声锥底面半径相关的椭圆形区域。

为了获得精确的外参 $\vec{n}$ 和 C ，采用基于优化的标定方法。收集包含 n 个已知三维空间坐标的标定点点 $\mathbf{X} = \{\mathbf{x}_i\}$ 及其对应的 SBES 距离测量值 m_i 的数据集。优化目标是最小化所有标定点到 SBES 的实际距离与 SBES 测量值之间的误差，同时约束每个标定点点位于其对应的声锥内部：

$$\begin{aligned} \arg \min_{C, \vec{n}} \sum_{i=1}^n (\|C\mathbf{x}_i - C\| - m_i)^2 \\ \text{s.t. } \forall C\mathbf{x}_i \in \mathbf{X}, o(C\mathbf{x}_i) \leq r_i \end{aligned} \quad (3-4)$$

其中， $o(C\mathbf{x}_i)$ 表示点 $C\mathbf{x}_i$ 到声锥轴线的垂直距离， $r_i = m_i \cdot \tan(\alpha)$ 为对应距离处的声锥底面半径。通过求解该非线性约束优化问题，即可获得高精度的外参估计 $\vec{n}$ 和 C ，为后续跨模态数据配准与融合奠定几何基础。

SBES 提供的深度值是稀疏且局部的，仅针对特定区域提供信息，无法覆盖整个场景。为克服这一限制，我们将 SBES 作为辅助传感器与单目相机集成。单目相机能够捕获丰富的视觉数据，但由于尺度模糊性问题，实现精确的绝对深度估计具有挑战性。虽然 SBES 的深度测量有限，但它们为单目相机提供了有价值的参考，有助于缓解尺度模糊性问题。通过将 SBES 的深度数据与单目视觉信息融合，我们可以实现更精确的深度估计，从而增强在复杂水下环境中的态势感知和安全评估能力。

完成标定后，即可将每个 SBES 测量值 m_i 准确地关联到图像上的特定区域 R ，实现视觉与声学数据的精确空间对齐。确定声呐投影区域后，需要将其与从原始 RGB 图像中提取的前景区域相交，生成融合掩码。




图 3-2 掩码生成流程：(a) 原始图像，(b) 前景分割后的图像，(c) 与回声测深仪结合后的掩码图像，(d) 稀疏处理后的掩码图像

Fig. 3-2 Mask generation process: (a) Original image, (b) Image after foreground segmentation, (c) Mask image after combining with echo sounder, (d) Mask image after sparse processing

在我们的方法中（图3-2），前景分割依赖于图像处理。在水下拍摄的图像常常会因为光线的散射和吸收而变得较暗，进行后续处理的时候，往往前景会变暗，不利于与声呐获取的深度信息进行结合。因此这里进行了 CLAHE（对比度限制自适应直方图均衡化）的方法来对灰度图进行图像增强，首先使用 CLAHE 算法进行图像增强，具体使用分水岭算法对图像进行分割并提取目标区域。这些区域然后在特定的圆形掩码内进行采样。由于该方法基于图像处理，提取的前景区域可能与训练好的语义分割网络产生的结果有所不同。因此，我们不是提取圆形掩码内的所有像素，而是根据一定的稀疏比率，将回声测深仪获得的深度值离散地分配给前景像素，随后进行进一步处理以优化深度估计。受文献^[74]启发，我们探索了如何确定回声探测器返回区域与单目相机捕获图像之间的对应关系。具体而言，我们将回声探测器声锥底部的圆形区域投影到相机捕获的图像上，并将其与前景分割识别的前景区域相交。然后，根据一



刻度板距离(m)	RGB图像	CLAHE处理图像	前景分割图像(gray)	前景分割图像(RGB)	声呐返回值(m)	预测深度图
0.850					0.792	
0.900					0.845	
0.950					0.900	
1.000					0.943	
1.050					0.988	
1.100					1.051	
1.150					1.100	

图 3-3 不同距离下的数据预处理流程及结果

Fig. 3-3 Data preprocessing pipeline and results at different distances

定的稀疏原则，将测量的深度值分配给交集集中的像素，如图3-2所示。这个过程进一步优化了 SBES 数据的空间对应关系，提高了深度估计的准确性，为后续的深度融合提供了必要条件。为了验证声呐与相机数据的对应关系以及预处理流程的有效性，我们在不同距离下进行了实验。实验设置如图3-3所示，声呐与水下相机保持在同一水平线，位于 5 cm 刻度线处。分别将水底遮挡物（海参、海草、魔方等）移动到刻度板的 85 cm、90 cm、95 cm、100 cm、105 cm、110 cm 处，每组测量 20 张图像。图3-3展示了在 7 个不同距离（0.900 m 至 1.150 m）下，从原始 RGB 图像到预测深度图的完整处理流程。从左至右分别为：刻度板距离、RGB 图像、CLAHE 处理图像、前景分割图像（灰度）、前景分割图像（RGB）、声呐返回值以及预测深度图。可以看到，在不同距离下，CLAHE 增强和前景分割能够有效提取目标区域，声呐返回值与真实距离基本一致，而预测深度图也反映了距离的变化。

3.3 深度融合网络框架设计

3.3.1 整体架构

本章提出的深度融合网络框架旨在协同利用单目图像的稠密纹理信息与 SBES 的稀疏绝对深度先验。如图3-4所示，整个流程包含三个核心阶段：(1) 基于改进 Trans-

former 的单目深度估计网络从输入图像生成初始相对深度图 D_{pred} ；(2) 利用标定后的 SBES 数据计算全局尺度因子，对 D_{pred} 进行初步尺度对齐，得到粗校正深度图 $\bar{D}$ ；(3) 通过残差高斯扩散模块，将 SBES 测量点处的局部深度残差自适应传播至整个深度图，输出精细化绝对深度图 $\hat{D}$ 。该方法的关键优势在于其自适应性，残差扩散机制考虑了空间邻近性和预测深度域的相似性，使得校正过程能更好地保持物体边缘和细节结构。




图 3-4 深度融合模块的详细流程

Fig. 3-4 The pipeline of depth fusion module in detail

3.3.2 单目相对深度估计网络

为获得结构准确的相对深度图，本章构建了一个单目深度估计网络。该网络的整体设计基于 ZoeDepth^[23] 与 DepthAnything^[24] 等先进工作，采用编码器-解码器 (Encoder-Decoder) 主干，并针对水下图像存在的退化现象（如模糊、低对比度、颜色失真）进行了针对性改进。网络的核心目标是从单张 RGB 图像 I 中预测出尺度未知但结构准确的相对深度图 D_{pred} ，为后续与 SBES 的绝对尺度融合提供可靠的几何先验。网络的具体架构流程如图 3-4 中蓝色部分所示。

网络采用**编码器-解码器**框架。编码器负责从输入图像中提取多层次、高语义的特征；解码器则将这些特征上采样并融合，逐步恢复至输入图像分辨率，并回归每个像素的深度值。编码器部分采用在大规模数据集上预训练的 DINOv2 模型作为骨干网络。

DINOv2 是一种自监督学习的视觉 Transformer 模型^[83]，它通过在大规模、多样化的图像数据集上进行预训练，学习到了强大的视觉特征表示。与基于文本指导的预训练方法不同，DINOv2 完全从图像本身学习特征，无需文本监督，因此能够保留更丰富的图像信息，包括复杂的像素级信息。该模型采用了改进的训练方法，包括图像级和块级的自监督学习目标，以及多种正则化技术，使其能够在无需微调的情况下，

在各种视觉任务上实现卓越的性能。

具体而言，DINOv2 模型在 LVD-142M 数据集上进行预训练，这是一个经过精心筛选和平衡的 142M 图像数据集，涵盖了多种视觉任务的数据源。该数据集的构建采用了自监督检索系统（如图3-5 所示），从大量未标注图像中检索与标注图像相似的样本，从而扩展数据集的规模和多样性。DINOv2 采用了改进的注意力机制、序列打包和完全分片数据并行等高效训练技术，使训练速度相比之前方法提升约 2 倍，内存使用减少至 1/3。此外，在预训练后期引入高分辨率训练阶段，显著提升像素级任务的性能。DINOv2 能够同时提取图像级的全局特征和块级的局部特征，这使得它既适用于图像分类任务，也适用于密集预测任务如语义分割和深度估计。

在深度估计任务中，我们使用预训练的 DINOv2 模型作为特征提取骨干。输入尺寸为 $H \times W \times 3$ 的图像，DINOv2 输出一组多尺度特征图 $\{F_l\}, l = 1, \dots, L$ ，其中 F_l 的空间尺寸逐层递减，但通道维度和语义抽象程度递增。这些特征捕捉了从底层纹理到高层语义的不同层次信息，为深度估计提供了丰富的视觉线索。




图 3-5 DINOv2 数据预处理流程

Fig. 3-5 Data processing pipeline of DINOv2

解码器设计采用密集预测变换器（Dense Prediction Transformer, DPT）^[84] 架构。DPT 是一种基于 Vision Transformer（ViT）的编码器-解码器架构，专为密集预测任务设计。如图 3-6（左）所示，输入图像首先被转换为令牌（tokens）：在 DPT-Base 和 DPT-Large 中，图像被划分为不重叠的图块并线性投影为令牌；在 DPT-Hybrid 中，则使用 ResNet-50 提取特征作为令牌。令牌与位置编码相加，并额外添加一个与图块无关的读出令牌。随后，令牌经过多个 Transformer 阶段处理，其特征维度在整个编码过程中保持恒定，且每个阶段均具有全局感受野。

在解码部分，DPT 通过 Reassemble 操作（图 3-6 中）将不同 Transformer 阶段输出的令牌重新组装成多分辨率的类图像特征表示。这些特征随后通过基于残差卷积单元的特征融合模块（图 3-6 右）逐步融合与上采样，最终生成精细化的预测。

ZoeDepth 网络（图 3-7）采用 DPT 作为其解码器架构，并遵循 MiDaS^[85] 的训练




图 3-6 密集预测变换器 (DPT) 架构

Fig. 3-6 Architecture of the Dense Prediction Transformer (DPT)

策略进行相对深度预测，使用尺度与偏移不变损失。当使用多个数据集时，采用多任务损失以确保跨数据集的帕累托最优性。在完成 MiDaS 式的相对深度预测预训练后，ZoeDepth 在解码器的瓶颈层及其后的四个层级（对应输入分辨率的 $1/32$ 、 $1/16$ 、 $1/8$ 、 $1/4$ 和 $1/2$ 处）附加了一个度量深度分箱（metric bins）模块。该设计使得网络能够同时进行相对深度与绝对深度估计。




图 3-7 ZoeDepth 架构

Fig. 3-7 ZoeDepth architecture

在我们的实现中，我们借鉴了这一思想，将 MiDaS 训练策略与 DINOv2 骨干网络结合。首先，编码器输出的多尺度特征经过一个瓶颈卷积层进行压缩，融合不同尺度的信息并降低计算复杂度，得到一个紧凑的、富含语义的特征表示。该特征随后输入一个基于 Patch 的 Transformer 模块，通过自注意力机制建模图像块之间的长程依赖关系，生成一个增强的全局特征嵌入，为深度估计提供连贯的场景级上下文。

深度回归采用了一种创新的分箱策略。首先，一个轻量级的种子箱回归器根据全局上下文特征，预测一组初始的离散深度区间（称为“种子箱”）及其中心值。这些种子箱提供了深度范围的一个粗略假设。随后，网络引入多个级联的吸引子模块。每个吸引子模块接收来自编码器-解码器不同尺度的局部特征块、当前的全局特征嵌入以及上一轮的箱中心与嵌入表示。通过交叉注意力等机制，吸引子模块迭代地优化和细

化这些深度箱的表示，使它们能够自适应地贴合图像中不同区域的真实深度分布。这种“由粗到细”的迭代优化机制，使得网络能够同时兼顾全局深度布局 and 局部细节结构。

经过多轮优化后，解码器输出的最终卷积特征与精炼后的深度箱嵌入相结合。通过一个条件对数二项层，网络计算每个像素属于各个深度箱的概率。最终的连续深度值 $D_{\text{pred}}(p)$ 通过对所有深度箱的中心值进行概率加权求和得到：

$$D_{\text{pred}}(p) = \sum_{k=1}^K P_k(p) \cdot c_k \quad (3-5)$$

其中， K 是深度箱的数量， $P_k(p)$ 是像素 p 属于第 k 个箱的概率， c_k 是该箱的中心深度值。这种方式保证了深度图的空间连续性和边缘清晰度。

3.3.3 基于 SBES 的绝对深度优化

单目网络预测的深度图 D_{pred} 具有正确的相对结构但缺乏绝对尺度。本阶段利用稀疏的 SBES 测量值 d_s 将其转化为度量准确的深度图，如图3-4 灰色部分所示。

首先进行全局尺度对齐。在图像平面上，根据标定外参确定 SBES 声锥的投影区域 R ，并在该区域内选取一组可靠的稀疏点 $p_s \in R_s$ ，每个点对应一个 SBES 测量值 d_s 。计算每个点处的尺度比率 $d_s/D_{\text{pred}}(p_s)$ ，并取其中位数作为全局尺度因子 α_s ：

$$\alpha_s = \text{median} \left(\frac{d_s}{D_{\text{pred}}(p_s)} \right) \quad (3-6)$$

应用该尺度因子得到初始的绝对深度图 $\bar{D}(p) = \alpha_s \cdot D_{\text{pred}}(p)$ 。

然而，简单的全局缩放可能因深度预测的局部误差而导致在 SBES 测量点附近仍存在残差。因此，提出残差高斯扩散机制进行局部优化。对于每个 SBES 测量点 p_s ，计算其深度残差 $r_s = d_s - \bar{D}(p_s)$ 。此残差需要被合理地传播到图像中的其他像素点 p 。

定义一个联合权重函数 $W_{ps}(p)$ ，该函数同时考虑了像素间的空间距离和它们在初始深度预测中的深度值相似性：

$$W_{ps}(p) = \exp \left(-\frac{\|p - p_s\|^2}{2\sigma_s^2} \right) \cdot \exp \left(-\frac{\mathcal{D}(D_{\text{pred}}(p), D_{\text{pred}}(p_s))}{2\sigma_d^2} \right) \quad (3-7)$$

其中，第一项基于空间欧氏距离，赋予邻近像素更高权重；第二项中， $\mathcal{D}(a, b) = (\log a - \log b)^2$ 度量深度值的对数差异，赋予深度值相似的像素更高权重。超参数 σ_s 和 σ_d 分别控制空间和深度域的平滑程度。这种设计使得残差的传播不仅局限于几何相邻区域，还能沿着在预测深度域中相似的区域进行传播。

最终，像素 p 处聚合的残差修正量 $R(p)$ 由所有 SBES 测量点的残差以其权重加

权平均得到：

$$R(p) = \frac{\sum_{p_s \in R_s} W_{ps}(p) \cdot r_s}{\sum_{p_s \in R_s} W_{ps}(p) + \epsilon} \quad (3-8)$$

其中 ϵ 为一个极小常数。优化后的最终深度图 $\hat{D}(p)$ 为：

$$\hat{D}(p) = \bar{D}(p) + R(p) \quad (3-9)$$

该优化过程无需迭代训练，效率极高，能够将稀疏的绝对深度信息以数据驱动的方式有效地融合到稠密的视觉深度估计中。

3.4 损失函数与训练策略

为有效地训练该深度估计网络，我们采用了混合监督损失函数。由于单目深度估计存在尺度模糊性，我们结合了两种在深度估计任务中广泛使用且互补的损失函数：**均方根误差损失 (RMSE)** 和 **尺度不变对数损失 (SILog)**。

均方根误差损失直接最小化预测深度与真实深度之间的绝对差异的平方根，侧重于降低整体预测误差：

$$\mathcal{L}_{\text{RMSE}} = \sqrt{\frac{1}{n} \sum_{i=1}^n (d_i - \hat{d}_i)^2} \quad (3-10)$$

其中 n 是有效像素的数量， d_i 和 $\hat{d}_i$ 分别表示第 i 个像素的真实深度值和预测深度值。

尺度不变对数损失在深度值的对数空间进行计算，对全局尺度变化不敏感，主要优化预测深度的相对结构和比例关系，有效缓解尺度模糊问题：

$$\mathcal{L}_{\text{SILog}} = \sqrt{\frac{1}{n} \sum_{i=1}^n g_i^2 - \frac{1}{n^2} \left(\sum_{i=1}^n g_i \right)^2} \quad (3-11)$$

其中 $g_i = \log d_i - \log \hat{d}_i$ 表示第 i 个像素的对数深度误差。

在 MiDaS 训练策略中，我们还引入了多数据集混合训练的损失函数设计。该策略旨在提升模型在不同环境中的训练稳健性，核心是通过多任务损失函数处理不同数据集之间的尺度不一致性。如果有多个数据集可用，则采用多任务损失以确保跨数据集的帕累托最优性：

$$\min_{\theta} (\mathcal{L}_1(\theta), \mathcal{L}_2(\theta), \dots, \mathcal{L}_L(\theta))^{\top} \quad (3-12)$$

其中 θ 为模型参数，在数据集之间共享， $\mathcal{L}_i(\theta)$ 表示在第 i 个数据集上的损失。

网络训练的总损失为 RMSE 损失和 SILog 损失的加权和：

$$\mathcal{L}_{\text{depth}} = \mathcal{L}_{\text{RMSE}} + \beta \mathcal{L}_{\text{SILog}} \quad (3-13)$$

其中 β 为平衡因子，在实验中设置为 1.0。

在训练策略方面，我们采用了 MiDaS 多数据集混合训练策略，这么做的目的是为了提升单目深度估计模型的训练稳健性，特别是在不同环境中执行的能力。该策略的核心是设计了一种新的损失函数，主要是解决不同类型的异构数据集之间存在的规模以及尺度方面的差异所带来的困扰。MiDaS 利用多任务的方法来使得模型能够更好的拟合各种不同类型的数据场景并且有更好的鲁棒性和泛化能力。每一个单独的数据集被当成一个不同的任务来进行训练，在此基础上使用多目标优化的方法使所有的小目标尽量靠近帕累托前沿。这种方法的核心是避免在某个数据集上减小损失时，导致其他数据集的损失增加，从而找到一个平衡点，确保模型能够在多个任务上有更好的效果。

从 MiDaS 最新版本实验显示，基于 BeiT-L-512 骨干网络具有最优效果，如图3-8所示。然而，DINOv2 在语义分割领域表现优异，而且参数量较低。因此，本研究将其更换为骨干网络后，性能相比 BeiT-L 模型有了较大提升。同时，得益于 DINOv2 的低参数量，模型的推理速度也明显加快。




图 3-8 各个模型在 MiDaS 策略上的性能比较

Fig. 3-8 Performance comparison of various models on MiDaS strategy

整个网络的训练分为两个阶段进行。第一阶段为单目深度估计网络的预训练，使用公开的大规模水下 RGB-D 数据集 FLSea VI^[64] 和 Sea-thru^[65]。这些数据集提供了成对的图像与深度真值，使网络能够学习水下场景的通用深度先验。训练使用 Adam 优化器，初始学习率为 1×10^{-5} ，批量大小设置为 2，共训练 20 个周期。输入图像统一调整为 480×640 分辨率。

第二阶段为端到端系统微调，使用自建的数据集，该数据集包含同步采集的单目

图像和 SBES 测量值。在这一阶段，深度估计网络的参数将与后续的 SBES 融合模块一同进行优化，以更好地适应特定传感器配置和任务需求，确保网络生成的相对深度图能够与 SBES 提供的绝对深度信息良好对齐。

通过上述网络设计、损失函数和训练策略，本节的单目深度估计网络能够从单张水下图像中稳健地预测出细节丰富、结构准确的相对深度图，为后续与绝对测距传感器（SBES）的深度融合提供了高质量的初始输入。

3.5 实验与分析

3.5.1 实验设置与评估指标

为全面评估所提出深度估计方法的性能，设置了仿真实验与真实水下实验。仿真实验在 HoloOcean 水下仿真环境中进行，便于进行系统的定量分析。真实实验则在室内水池和青岛近海区域开展，使用搭载了相机和 SBES 的 ROV 平台进行数据采集。

采用以下深度估计评估指标进行定量分析：

- **绝对相对误差 (AbsRel)** : $\frac{1}{N} \sum_i |d_i - \hat{d}_i| / d_i$
- **均方根误差 (RMSE)** : $\sqrt{\frac{1}{N} \sum_i (d_i - \hat{d}_i)^2}$
- **对数均方根误差 (RMSElog)** : $\sqrt{\frac{1}{N} \sum_i (\log d_i - \log \hat{d}_i)^2}$
- **阈值准确率 (δ_k)** : $\max(\frac{d_i}{\hat{d}_i}, \frac{\hat{d}_i}{d_i}) < 1.25^k$ 的像素百分比
- **平均相对误差 (MRE)** : $\frac{1}{N} \sum_i |d_i - \hat{d}_i| / d_i \times 100\%$

3.5.2 深度估计性能对比

将提出的方法（Ours）与当前先进的单目深度估计方法进行了对比，包括 BTS、AdaBins、ZoeDepth、NewCRFs、Depth-Anything-V2-Small、Depth-Anything-V2-Base 和 ECoDepth。所有对比方法在相同的训练集上进行训练或微调，并在统一的测试集（FLSea VI 和 Sea-thru 数据集）上评估。定量结果如表3-1 所示。

如表3-1 所示，提出的方法（Ours）在多项关键指标上取得了较好性能。在绝对相对误差 (AbsRel)、均方根误差 (RMSE) 和对数均方根误差 (RMSElog) 上，我们的方法均优于所有对比方法，展示了更高的深度估计精度。具体而言，我们的 AbsRel 误差低至 0.057，优于其他方法。尽管在 δ_1 指标上略低于经过微调的 Depth-Anything-V2-Base 模型 (0.968 vs. 0.973)，但在 δ_3 指标上取得了最优结果 (0.996)。

此外，我们的模型在效率和性能之间取得了良好的平衡。模型参数量仅为 26M，远低于 ZoeDepth (345M) 和 ECoDepth (993M) 等大型模型，与最轻量的 Depth-Anything-

表 3-1 深度估计性能定量比较

Table. 3-1 Quantitative comparison of monocular depth estimation performance

方法	微调	AbsRel↓	RMSE↓	RMSElog↓	参数量	$\delta_1 \uparrow$	$\delta_2 \uparrow$	$\delta_3 \uparrow$
BTS	-	0.175	0.552	0.197	47M	0.819	0.928	0.962
AdaBins	√	0.158	0.360	0.170	78M	0.849	0.940	0.967
ZoeDepth	-	0.157	0.466	0.140	345M	0.889	0.980	0.993
NewCRFs	-	0.086	0.396	0.119	270M	0.919	0.968	0.987
Depth-Anything-V2-Small	√	0.071	0.373	0.104	25M	0.966	0.991	0.995
Depth-Anything-V2-Base	√	0.065	0.345	0.095	98M	0.973	0.992	0.995
ECoDepth	√	0.247	0.858	0.320	993M	0.384	0.850	0.972
Ours	-	0.057	0.340	0.093	26M	0.968	0.991	0.996

V2-Small 模型（25M）相当，同时在主要指标上表现更优。值得注意的是，AdaBins、Depth-Anything-V2 系列及 ECoDepth 均在目标数据集上进行了微调，而我们的方法未进行微调，这进一步体现了其优秀的泛化能力与稳健性。




图 3-9 深度估计定性对比

Fig. 3-9 Qualitative comparison of monocular depth estimation

图3-9 展示了不同方法在具有挑战性的水下场景中的深度估计结果定性对比。可以看出，基于纯视觉的方法在纹理弱或光线差的区域容易出现估计模糊或错误。而我们的方法得益于 SBES 提供的绝对尺度引导和残差扩散优化，生成的深度图不仅整体尺度准确，而且在细节结构上更加清晰、连续，与场景的真实几何吻合得更好。

3.5.3 融合策略消融实验

为全面验证所提出的残差高斯扩散（Residual Gaussian Diffusion, RGD）模块的有效性，本节在搭建的人工测试平台上进行了对比实验。该平台集成了一个分辨率为 1920×1080 的水下相机和一个低成本的 P30 单波束测距声呐（测量范围为 $0 \sim 30\text{m}$ ，测量精度为 0.5% ），如图 3-10 所示。实验在可控水池环境中进行，设计了两个 $8\text{ cm} \times 8\text{ cm} \times 8\text{ cm}$ 的魔方以及上方放置的重物块作为声呐反射目标。通过将目标物体重新放置在七个标记位置，收集了声呐读数与图像数据。在注水前，通过立体视觉方法获取了地面真实深度，为后续的定量评估提供了可靠的基准。




图 3-10 人工平台系统

Fig. 3-10 The artificial platform system

在此实验设置基础上，选取了三种形态各异的物体（记为物体 A、B、C）作为测试对象，以全面评估不同融合策略的性能。所对比的四种策略及其对应关系如下：

- **Baseline（无融合）**：即图中的“Raw”，直接使用单目深度估计网络输出的原始深度图，不进行任何基于 SBES 的尺度校正；
- **MDSS（最小深度全局缩放）**：即图中的“①Fusion”，将声呐锥体（cone）内的最近距离（SDS）与图像中对应区域的最近距离直接进行全局尺度标定；
- **MDAS（平均深度全局缩放）**：即图中的“②Fusion”，在图像中声呐锥体区域内，去除深度极大值与极小值后计算平均深度作为参考，再将整个深度图按 SDS 与此参考深度的比例进行全局缩放；

- **RGD (残差高斯扩散)**: 即图中的“③Fusion”, 本文所提出的方法, 利用声呐测量构建基于高斯分布的残差场, 通过扩散机制对原始深度图进行局部、非线性的精细校准。与 MDAS 策略的主要区别在于引入了残差误差扩散过程。

图3-11 对比了四种策略在物体 A、B、C 上、不同预设尺度因子 (0.850 至 1.150) 下的深度估计结果与真实值。可以看到, Baseline 方法 (Raw) 的估计值随尺度变化波动较大, 且整体偏离真实值。MDSS (①Fusion) 与 MDAS (②Fusion) 通过全局缩放修正了部分尺度偏差, 估计曲线整体向真实值靠近, 但在尺度因子两端仍存在一定误差。相比之下, 本文提出的 RGD 方法 (③Fusion) 在不同物体和整个尺度区间内的估计值均更贴近真实值, 波动幅度最小, 表明该方法对物体形态和尺度变化具有较好的适应性。



Scenario							
Distance (m)							
True A	0.850	0.900	0.950	1.000	1.050	1.100	1.150
Raw A	1.503	1.504	1.657	1.630	1.631	1.577	1.657
①Fusion A	1.167	1.326	1.413	1.472	1.545	1.641	1.858
②Fusion A	0.786	0.862	0.889	0.921	0.978	1.049	1.189
③Fusion A	0.856	0.923	0.953	0.986	1.044	1.118	1.257
True B	0.900	0.950	0.950	1.000	1.050	1.050	1.150
Raw B	1.617	1.564	1.756	1.709	1.666	1.564	1.586
①Fusion B	1.256	1.341	1.498	1.543	1.578	1.627	1.779
②Fusion B	0.840	0.886	0.942	0.966	0.995	1.042	1.139
③Fusion B	0.921	0.958	1.010	1.035	1.066	1.111	1.202
True C	0.900	0.950	0.950	0.950	1.000	1.110	1.150
Raw C	1.550	1.537	1.578	1.570	1.548	1.583	1.594
①Fusion C	0.861	0.925	0.889	0.934	0.973	1.115	1.210
②Fusion C	0.806	0.881	0.848	0.887	0.926	1.055	1.132
③Fusion C	0.882	0.944	0.907	0.950	0.991	1.123	1.197

图 3-11 不同物体上各融合策略的深度估计性能对比

Fig. 3-11 Depth estimation performance comparison of different fusion strategies on various objects

为进行更严格的量化评估, 在该人工实验平台采集的数据集上对上述四种策略进行了综合测试。除了均方误差 (MSE) 和均方根误差 (RMSE) 外, 还采用了平均绝对误差 (MAE)、平均绝对百分比误差 (MAPE)、决定系数 (R^2) 以及相关系数 (R) 进行评估。其中, MAPE 以百分比形式反映相对误差, 直观衡量估计精度; R^2 衡量预测值对真实值的拟合优度, 越接近 1 表明模型拟合越好; R 量化预测值与真实值之间的线性相关程度, 绝对值越接近 1 表示线性相关性越强。

定量结果如表3-2 所示。从表中可以看出, 提出的融合策略在所有评估指标上均优于对比方法。MDAS 策略通过利用声呐锥体区域内的深度统计信息进行全局校正,

其性能显著优于仅使用最近距离进行缩放的 MDSS 策略，这验证了稀疏点选择过程确保全局尺度正确对齐的有效性。而 RGD 策略 (③Fusion) 进一步通过高斯权重扩散残差误差，实现了比 MDAS 策略更高的精度，证明所提出的残差扩散过程能够进一步提升深度估计性能。

表 3-2 不同融合策略性能定量对比

Table. 3-2 Quantitative comparison of different fusion strategies

融合策略	MSE↓	RMSE↓	MAE↓	MAPE↓ (%)	R ² ↑	R ↑
Baseline (Raw)	0.2154	0.4641	0.3897	36.74	-45.21	0.9621
MDSS (Fusion)	0.1738	0.4169	0.3441	32.33	-22.33	0.9725
MDAS (Fusion)	0.0037	0.0609	0.0542	5.23	0.5271	0.9754
RGD (Fusion, Ours)	0.0014	0.0374	0.0270	1.65	0.8152	0.9784

从定量结果来看，像素级深度估计的整体相对误差为 1.65%，略高于 P30 声呐自身的测距精度 (0.5%)。误差主要来源于三个方面：一是水池实验中的水面反射会在底部产生镜像映射，部分区域出现虚像，导致模型难以区分真实物体与镜面伪影；二是声波在传播路径上过早触及底部或障碍物，回波提前返回引入“过早触底”误差；三是传感器安装偏差与时间同步误差在融合阶段放大了测量偏差。尽管如此，整体 MSE 与 RMSE 指标表明，该方法在不同目标和距离下仍保持了较好的深度估计一致性，对复杂水下场景具有较好的适应能力。

综上，消融实验从定性与定量两方面验证了本文提出的残差高斯扩散 (RGD) 融合策略的有效性。相比无融合基准和现有全局缩放策略，RGD 能够更充分地利用稀疏声呐绝对深度信息，对单目深度估计结果进行校正，在精度和稳定性上均表现更优，为提升水下单目深度估计的实用性提供了可行方案。

3.5.4 真实水下环境测试

为评估所提算法在完全未知、非结构化的真实海洋环境中的性能，在青岛近岸浅水区域进行了实地测试。测试平台由一台轻量化 ROV (Fifish V-EVO) 搭载单目相机和 P30 单波束测距声呐组成，如图3-12 所示。其中，ROV 负责实时采集水下图像数据，而声呐测量数据则通过水面控制电脑同步获取，实现了图像与声呐数据在时间上的精确同步。

由于在开阔水域中难以获取像素级的真实深度数据，本研究主要通过对融合后深度图进行定性分析来验证算法的实用性。图3-13 展示了在真实水下环境中采集的 RGB 图像 (上排) 及经过所提出的 SBES 融合优化后的深度估计结果 (下排)。从图




图 3-12 真实水下环境测试平台（青岛近岸）

Fig. 3-12 Field test platform in Qingdao coastal waters

中可以看出，在复杂的光照变化、悬浮颗粒及动态水波的干扰下，经过融合优化的深度图展现出良好的实用特性：整体尺度符合物理世界的真实距离感，局部细节（如海草、岩石、螃蟹、海参的轮廓）清晰准确，深度变化平滑自然，与人类视觉感知的场景三维结构高度一致。这表明所提出的融合方法能够有效利用稀疏的声呐绝对深度信息，在真实复杂水下环境中生成合理、可靠的深度估计结果，具备实际应用的潜力。




图 3-13 实验水下环境中的 RGB 图像与深度估计结果

Fig. 3-13 RGB images and corresponding depth estimation results in real underwater environment

实地测试结果表明，所提出的融合方法在真实、具有挑战性的水下环境下保持了精度。即使在能见度较低、光照不均的条件下，该方法仍能生成尺度准确且细节保留较好的深度估计，为水下机器人导航、目标探测等应用提供了可靠的环境感知支持。

3.6 本章小结

本章针对水下环境中单目深度估计的尺度模糊和精度不足问题，提出了一种基于 SBES 与视觉融合的深度估计方法。首先，建立了一套精确的相机-SBES 跨模态标定与数据配准流程，为异构传感器的信息融合奠定了几何基础。其次，设计了一个层次化的深度融合网络框架，该框架以改进的单目深度估计网络为前端，提供稠密的相

对深度感知；而后端则创新性地提出了 RGD 机制，利用稀疏的 SBES 绝对深度测量，以数据驱动且符合空间-深度相似性规律的方式，对前端预测进行尺度校正与结构优化。最后，通过系统的仿真与真实环境实验，验证了所提方法的优越性。定量结果表明，该方法在多个标准深度估计指标上优于现有先进方法。消融实验证实了 RGD 模块相比于简单全局缩放策略的显著优势。实地测试则展示了算法在复杂真实海洋环境中的良好适应性和实用性。本章工作为轻量化、低成本的水下机器人平台提供了一种高精度、鲁棒的深度感知解决方案，为后续的态势感知与自主避障奠定了坚实的感知基础。

4 基于视觉-SBES 融合的态势感知

4.1 方法概述

在第三章工作的基础上，本章进一步探索水下环境的语义层面的环境理解问题，提出一种面向水下环境的态势感知方法（SA-net）。虽然精确的几何深度感知为 AUV 导航提供了重要基础，但在复杂的动态水下环境中，仅依靠深度信息仍难以实现智能的自主决策。AUV 需要能够评估环境的整体安全状况，理解不同区域的风险等级，并对潜在的动态威胁做出预判。因此，本章将第三章所获得的度量准确深度信息与视觉时序分析相结合，从单目视频序列中提取环境的动态特征，并融合几何深度信息，实现对水下场景安全等级的像素级评估。通过引入态势感知的概念，我们将这一概念具体化为一个像素级的三分类任务：根据区域的动态特性、深度信息和视觉特征，将其划分为“危险”、“警告”或“安全”三个等级。本章方法的核心是多层次特征的有效融合，一方面通过视频预测网络提取时序动态特征，捕捉水下物体的运动趋势和场景的变化模式；另一方面利用第三章构建的 SBES 融合深度图提供准确的几何距离信息；最后通过改进的 U-Net 网络将这些特征与原始 RGB 图像进行融合，生成端到端的态势感知图，整体流程框架如图4-1 所示。整体而言，本章工作是对第三章深度感知研究的进一步应用和拓展，实现了从“几何感知”到“语义理解”的认知提升，为后续的自主避障与智能决策奠定了坚实基础。




图 4-1 基于视觉-SBES 融合的态势感知框架

Fig. 4-1 Vision-SBES fusion based situational awareness framework

4.2 态势感知网络架构设计

4.2.1 整体架构

态势感知网络以单目相机捕获的连续视频帧、以及第三章输出的精炼深度图作为输入，输出为与输入图像同分辨率的像素级安全等级图 $S_t \in \mathbb{R}^{H \times W \times 3}$ ，其中三个通道分别对应“危险”、“警告”、“安全”类别的概率。该过程可形式化表示为：

$$S_t = f_{SA}(I_t, \Delta I_t, \hat{D}_t) \quad (4-1)$$

其中 I_t 为当前帧 RGB 图像， ΔI_t 为动态预测差异图， $\hat{D}_t$ 为融合 SBES 的绝对深度图， f_{SA} 为态势感知网络。

与传统的识别^[86]和分类^[87]方法不同，本研究中水下态势的特征在于其复杂性和动态变化性。换言之，安全等级主要由态势的混乱程度定义。因此，所提出的态势感知模块由两个组件构成：分析混乱模式的差异预测模型和评估环境整体复杂性的上下文理解模型。态势感知模块中的数据流流程和网络结构如图4-2所示。




图 4-2 态势感知模块网络详细架构

Fig. 4-2 Detailed network architecture of the situational awareness module

网络整体采用编码器-解码器结构，并在编码器中引入了空间与通道注意力模块，以增强对关键区域的聚焦能力。具体而言，网络包含三个核心子模块：动态信息提取模块（Difference Prediction Module）利用预训练的视频预测网络生成帧间差异图，引导态势感知网络（Situational Awareness Module）关注动态变化区域；多特征融合编码器将 RGB 与深度图进行通道拼接，并通过卷积层提取多尺度特征；注意力引导的解码器在解码过程中引入注意力机制，逐步上采样并融合深浅层特征，最终输出三分类分割图。

4.2.2 动态信息提取

水下环境中普遍存在动态变化现象，例如海草随水流摆动、鱼类游动以及缆绳和柔性结构的晃动等。这类动态目标往往具有不确定性强、形态变化快的特点，在水下航行任务中可能引入潜在风险。为有效表征环境中的时序变化信息，本文设计了一种基于卷积神经网络的动态信息提取模块，用于从连续图像序列中提取帧间运动特征，并生成反映环境动态变化程度的差异图。

动态信息提取模块的整体结构如图 4-3 所示。需要说明的是，该图为时间差分关系的示意图，用于直观展示多步预测机制与帧间差分构造方式之间的对应关系，而非严格的网络训练或推理流程图。模块核心采用一个多步预测网络，该网络基于轻量化的编码器-解码器结构设计，以当前时刻的 RGB 图像作为输入，预测未来多个时间步内的帧间变化趋势，并输出对应的差分结果。




图 4-3 多步预测差分模块示意图

Fig. 4-3 Schematic diagram of the multi-step prediction difference module

如图 4-3 所示，给定连续的五帧图像序列 $\{I_n, I_{n+1}, I_{n+2}, I_{n+3}, I_{n+4}\}$ ，预测差分分支以当前帧 I_n 为参考，通过多步预测策略（step = 3）生成未来三个时间步的动态变化

信息。图中上方展示的是预测得到的差分结果，用于描述从当前帧 I_n 到未来帧 I_{n+1} 、 I_{n+2} 以及 I_{n+3} 之间的变化趋势；下方则表示由真实观测帧直接计算得到的相邻帧差分，用于刻画环境中实际发生的动态变化。通过这种方式，网络能够学习场景中具有一致性和可预测性的运动模式，并对突发变化或复杂运动区域产生较大的预测误差响应。

动态信息提取网络采用编码器-解码器结构，由三个连续的编码块及其对应的解码块组成。编码器部分逐层提取输入图像的多尺度特征，每个编码块由卷积层、ReLU 激活函数以及最大池化层构成，其计算过程可表示为：

$$E_k = \text{MaxPool2D}(\text{ReLU}(\text{Conv2D}(E_{k-1}))), \quad (4-2)$$

其中 $E_0 = I_t$ 表示输入的当前时刻图像， $k = 1, 2, 3$ 表示编码层索引。解码器部分通过转置卷积逐步恢复特征图空间分辨率，并引入跳跃连接以融合编码阶段的多尺度特征，其计算过程表示为：

$$D_j = \text{ConvTranspose2D}(\text{Concat}(D_{j-1}, E_{3-j})), \quad (4-3)$$

其中 $j = 1, 2, 3$ 表示解码层索引， $\text{Concat}(\cdot)$ 表示在通道维度上的特征拼接操作。网络最终输出通过 Sigmoid 激活函数进行归一化，得到原始预测差分结果：

$$\Delta I_t^{\text{raw}} = \text{Sigmoid}(D_3). \quad (4-4)$$

在多步预测设置下，网络同时输出多个未来时间步的预测结果。本文设定预测步数为 3，并取第一个时间步的输出作为当前时刻的动态差异图基础：

$$\Delta I_t^{\text{base}} = \Delta I_t^{\text{raw}}[:, 0, :, :, :]. \quad (4-5)$$

为消除不同场景和光照条件对数值范围的影响，对预测结果进行归一化处理：

$$\Delta I_t = \frac{\Delta I_t^{\text{base}} - \min(\Delta I_t^{\text{base}})}{\max(\Delta I_t^{\text{base}}) - \min(\Delta I_t^{\text{base}})}. \quad (4-6)$$

随后，将归一化后的结果映射为 8 位灰度图像，用于可视化和后续特征融合：

$$\Delta I_t^{\text{visual}} = \text{clamp}(\Delta I_t \times 255, 0, 255). \quad (4-7)$$

动态差异图反映了模型对环境变化的预测不确定性。当场景中目标运动规律稳定、变化连续时，预测结果与真实观测之间的差异较小，对应区域在差异图中呈现为低响应；而当环境中出现剧烈运动、非刚性形变或新目标进入视野时，预测误差显著增大，在差异图中表现为高亮区域。这些高响应区域通常对应潜在风险较高的位置，

可为后续安全评估提供重要线索。

在多步预测网络的训练阶段，采用预测差分与真实帧间差分之间的像素级损失函数对网络进行监督，其目标是 최소화 预测差分与真实差分之间的差异，损失函数定义为：

$$\mathcal{L}_{\text{diff}} = \frac{1}{S} \sum_{s=1}^S \left\| \Delta I_{t+s}^{\text{pred}} - \Delta I_{t+s}^{\text{gt}} \right\|_1, \quad (4-8)$$

其中 S 表示预测步数， $\Delta I_{t+s}^{\text{pred}}$ 和 $\Delta I_{t+s}^{\text{gt}}$ 分别表示第 s 个时间步的预测差分与真实差分。通过该损失约束，网络能够有效学习环境中的时序动态特征。

在态势感知框架的整体训练过程中，动态信息提取模块采用预训练权重并保持参数固定，其输出的动态差异图作为辅助信息，与 RGB 图像以及第三章生成的深度图共同输入特征融合网络，从而在不增加训练复杂度的前提下，引入对环境动态变化的显式建模，增强系统对复杂水下场景的理解能力。

4.2.3 特征融合网络设计

本文采用 U-Net 作为特征融合网络的主体架构^[88]进行改进。U-Net 最初于 2015 年被提出，用于解决生物医学图像分割问题，其优异的性能使其迅速扩展应用于卫星图像分割、工业缺陷检测等多个领域。该网络得名于其 U 型的对称编码器-解码器结构，其核心优势在于特征复用、参数共享、语义连贯以及独特的跳跃连接机制。




图 4-4 U-Net 网络结构

Fig. 4-4 U-Net network architecture

如图4-4 所示，U-Net 结构由编码器、隐藏层和解码器三部分构成。编码器包含

四个下采样阶段，每个阶段有两组连续的 3×3 卷积层，每层后接 ReLU 激活函数进行非线性变换，然后使用核为 2×2 的最大池化层进行下采样，使特征图空间尺寸减半。这个过程重复四次，逐步提取并压缩输入图像的高级语义特征。隐藏层位于网络最底部，是编码器与解码器之间的桥梁，其结构与编码器阶段类似，通过两组 3×3 卷积层进一步融合和提炼最深层的特征表示，但不进行下采样。解码器包含四个上采样阶段，与编码器对称。每个阶段首先使用转置卷积（反卷积）将特征图的尺寸扩大一倍，随后通过跳跃连接将上采样后的特征与编码器对应阶段提取的同分辨率特征图进行通道拼接。拼接后的特征再经过两组 3×3 卷积层与 ReLU 激活函数处理，以融合低层细节与高层语义。网络最终通过一个 1×1 卷积层输出像素级分类结果。

选择 U-Net 作为本任务的基础网络，主要基于其架构特性。该网络的编码器-解码器结构能有效提取并融合来自不同源输入的多层次特征信息；跳跃连接机制将编码路径中富含空间细节的浅层特征直接传递至解码路径，这对于在训练数据规模有限的情况下保留目标边界、提升模型泛化能力至关重要；同时，U-Net 具备像素级分类能力，能够输出与输入同分辨率的密集预测图，非常适合生成精细化的像素级态势评估图。

为增强网络对水下复杂场景关键信息的感知与判别能力，我们在原始 U-Net 基础上进行了两处核心改进分别是**双分支多源特征融合架构**和**多层级注意力机制的增强**。

在**双分支多源特征融合架构**方面，网络采用双分支编码器设计，分别处理 RGB 图像和动态差异图，而非简单的通道拼接。具体结构如图4-2 所示。主干分支的输入为三通道 RGB 图像 I_t 与单通道深度图 $\hat{D}_t$ 。在输入网络前，先将 RGB 图像转换为灰度图，然后与深度图在通道维度拼接，形成两通道输入。该两通道输入通过标准的 U-Net 编码器（包含 4 个下采样阶段）提取多尺度特征 e_1, e_2, e_3, e_4, e_5 。差分分支的输入为单通道动态差异图 ΔI_t ，通过一个轻量级特征提取网络进行处理，该网络由三个卷积层构成，通过步长为 2 的下采样逐步压缩空间维度，最终输出与主干分支 e_3 层空间分辨率匹配的特征图。特征融合在编码器的中间层进行，具体而言，将差分分支提取的特征通过双线性插值调整至与主干分支 e_2 层相同的空间尺寸，并利用 1×1 卷积调整通道数。随后通过注意力门控机制计算差分特征对主干特征的注意力权重，将加权的差分特征与 e_2 特征在通道维度拼接，最后通过 1×1 卷积实现自适应融合：

$$\tilde{e}_2 = \text{Conv}1 \times 1([\mathcal{A}(e_2, \text{Interp}(\Delta))]) \quad (4-9)$$

其中 $\mathcal{A}(\cdot)$ 表示注意力门控操作， $\text{Interp}(\cdot)$ 表示空间尺寸调整， $[\cdot]$ 表示通道拼接。这种设计使得网络能够动态调整不同模态特征的贡献，增强对动态变化区域的感知能力。

在**多层级注意力机制增强**方面，我们在编码器的每个阶段后引入并发空间与通道挤压激励模块（scSE）^[89]，该模块通过空间与通道双维度的注意力校准，增强特征表示能力。scSE 模块由两个并行的子模块构成：通道挤压激励（cSE）与空间挤压激励

(sSE)。二者分别从通道维度和空间维度计算注意力权重，并通过逐元素相加的方式进行融合，从而实现了对特征图的自适应重校准。scSE 模块的结构如图4-5 所示。该模块可以无缝集成到任何卷积神经网络中，仅增加少量参数即可显著提升模型对重要特征的关注意力，抑制无关信息，进而提升网络性能。




图 4-5 scSE 注意力模块结构

Fig. 4-5 Structure of the scSE attention block

给定输入特征图 $\mathbf{U} \in \mathbb{R}^{H \times W \times C}$ ，通道挤压激励 (cSE) 分支的计算过程如下：

$$\mathbf{z} = \text{GAP}(\mathbf{U}) \in \mathbb{R}^{1 \times 1 \times C}, \quad z_k = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W \mathbf{u}_k(i, j) \quad (4-10)$$

$$\hat{\mathbf{z}} = \mathbf{W}_2 \cdot \delta(\mathbf{W}_1 \cdot \mathbf{z}), \quad \mathbf{W}_1 \in \mathbb{R}^{C/r \times C}, \quad \mathbf{W}_2 \in \mathbb{R}^{C \times C/r} \quad (4-11)$$

$$\hat{\mathbf{U}}_{cSE} = [\sigma(\hat{z}_1)\mathbf{u}_1, \sigma(\hat{z}_2)\mathbf{u}_2, \dots, \sigma(\hat{z}_C)\mathbf{u}_C] \quad (4-12)$$

其中 GAP 表示全局平均池化， δ 为 ReLU 激活函数， σ 为 Sigmoid 函数， r 为降维比率。空间挤压激励 (sSE) 分支的计算过程如下：

$$\mathbf{q} = \mathbf{W}_{sg} * \mathbf{U}, \quad \mathbf{W}_{sg} \in \mathbb{R}^{1 \times 1 \times C \times 1} \quad (4-13)$$

$$\hat{\mathbf{U}}_{sSE} = [\sigma(q_{1,1})\mathbf{u}^{1,1}, \sigma(q_{1,2})\mathbf{u}^{1,2}, \dots, \sigma(q_{H,W})\mathbf{u}^{H,W}] \quad (4-14)$$

其中 $*$ 表示卷积操作， $\mathbf{u}^{i,j} \in \mathbb{R}^{1 \times 1 \times C}$ 表示位置 (i, j) 处的特征向量。最终，scSE 模块的输出通过逐元素相加得到：

$$\hat{\mathbf{U}}_{scSE} = \hat{\mathbf{U}}_{cSE} + \hat{\mathbf{U}}_{sSE} \quad (4-15)$$

这种融合方式确保了特征图中的每个位置-通道组合 (i, j, c) 的激活程度同时受到

通道重要性和空间重要性的双重调节，当某个特征同时在通道和空间维度上被识别为重要时，其激活值将得到进一步增强，从而鼓励网络学习更具判别力的特征表示。通过在多层级引入 scSE 注意力机制，网络实现了对关键语义区域与特征通道的动态聚焦，显著提升了特征融合的效能与最终变化检测的准确性。

4.3 损失函数与训练策略

态势感知数据集中，“危险”与“安全”区域通常占比较大，而“警告”区域（如动态障碍物的运动范围）往往样本稀少，导致严重的类别不平衡。若使用标准交叉熵损失，网络会倾向于忽略“警告”类别的学习。

4.3.1 加权交叉熵损失

针对水下态势评估数据集中存在的类别不平衡问题，本文采用加权交叉熵损失作为训练目标。标准交叉熵损失函数定义为：

$$\mathcal{L}_{CE} = - \sum_{i=1}^C y_i \log(p_i) \quad (4-16)$$

其中 $C = 3$ 表示类别数（对应危险、警告、安全三类）， y_i 为独热编码形式的真实标签向量， p_i 为模型预测的类别概率值。

为了有效平衡各类别对损失函数的贡献，特别针对样本数量较少的“警告”类别进行增强学习，本文引入类别权重系数 w_i ，构建加权交叉熵损失函数：

$$\mathcal{L}_{WCE} = - \sum_{i=1}^C w_i \cdot y_i \log(p_i) \quad (4-17)$$

权重系数 w_i 的设置直接影响模型对不同类别的关注程度和最终学习效果。通过大量实验对比和参数调优，确定了一组在整体性能和各类别检测精度之间取得最佳平衡的权重组合：

$$w = \{w_{\text{危险}}, w_{\text{警告}}, w_{\text{安全}}\} = \{1.2, 1.5, 1.0\} \quad (4-18)$$

在该权重配置中，“警告”类别的权重系数最高（1.5），这反映了其在数据集中样本相对稀缺但在实际应用中航行安全具有重要预警价值的双重特性；“危险”类别的权重系数设定为 1.2，强调了模型对高风险区域识别准确性的重视；“安全”类别作为基准类别，权重系数设为 1.0。这样的权重分配策略确保了模型在训练过程中能够更加关注少数类别和关键类别，有效缓解了类别不平衡带来的学习偏差问题。

在训练过程中，加权交叉熵损失通过反向传播算法优化网络参数。对于类别 i ，其

梯度计算方式如下：

$$\frac{\partial \mathcal{L}_{WCE}}{\partial z_i} = w_i \left(\frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)} - y_i \right) \quad (4-19)$$

其中 z_i 是网络输出的类别 i 的 logit 值。通过权重系数 w_i 对梯度信号进行调制，放大了少数类别和关键类别在参数更新过程中的影响力，促使网络更加关注这些类别的特征学习，从而提升模型在类别不平衡场景下的整体性能表现。

4.3.2 训练策略

训练采用批量大小为 8 的数据加载器，并固定随机种子以保证实验可重复性。损失函数使用加权交叉熵以处理类别不平衡，同时结合 Lovász-Softmax 损失优化分割精度。优化器选择 Adam，初始学习率为 1×10^{-4} ，并使用 StepLR 调度器每 5 个 epoch 衰减 20%。模型在每个 epoch 后在验证集上评估多种指标，包括像素精度、类别像素精度、平均交并比 (MIOU) 及加权交并比 (FWIoU)，并根据验证集性能动态保存最佳模型。训练过程中，同时记录学习率、每类 MIOU 及训练/验证损失变化，用于性能分析和可视化。

4.4 实验与分析

4.4.1 评估指标

为全面、客观地评估水下环境态势感知模型的性能，本文采用语义分割任务中常用的多维评估指标体系，包括交并比 (Intersection over Union, IoU)、平均交并比 (Mean Intersection over Union, MIOU)、频权交并比 (Frequency Weighted IoU, FWIoU)、像素精度 (Pixel Accuracy, PA) 和平均像素精度 (Mean Pixel Accuracy, MPA)。假设模型需要区分的总类别数为 $M + 1$ 个 (本文中对应危险、警告、安全三类，即 $M = 2$)，令 p_{ij} 表示混淆矩阵 (Confusion Matrix) 中真实类别为 i 但被模型预测为类别 j 的像素数量。

交并比 (IoU) 是衡量模型分割精度的核心指标，反映了预测分割区域与真实标注区域之间的重叠程度。对于单个类别 i ，其 IoU 值计算公式为：

$$\text{IoU}_i = \frac{TP_i}{TP_i + FP_i + FN_i} \quad (4-20)$$

其中 TP_i (True Positive) 表示正确预测为类别 i 的像素数， FP_i (False Positive) 表示错误预测为类别 i 的像素数， FN_i (False Negative) 表示真实为类别 i 但被错误预测为其他类别的像素数。

平均交并比 (MIOU) 是模型整体分割性能的关键度量指标，通过对所有类别的

IoU 值取平均获得：

$$MIoU = \frac{1}{M+1} \sum_{i=0}^M IoU_i = \frac{1}{M+1} \sum_{i=0}^M \frac{p_{ii}}{\sum_{j=0}^M p_{ij} + \sum_{j=0}^M p_{ji} - p_{ii}} \quad (4-21)$$

其中 p_{ii} 是混淆矩阵对角线上的元素，表示类别 i 的预测正确像素数。MIoU 值越接近于 1，表明模型的分割结果与真实标注的重叠程度越高，分割性能越优异。

考虑到水下态势评估数据集中存在的显著类别不平衡问题，特别是“警告”区域在图像中通常占据较小面积这一特性，频权交并比 (FWIoU) 通过引入类别频率权重，提供了更为合理和平衡的性能评估：

$$FWIoU = \sum_{i=0}^M \left(\frac{\sum_{j=0}^M p_{ij}}{\sum_{l=0}^M \sum_{j=0}^M p_{lj}} \right) \cdot \frac{p_{ii}}{\sum_{j=0}^M p_{ij} + \sum_{j=0}^M p_{ji} - p_{ii}} \quad (4-22)$$

式中 $\frac{\sum_{j=0}^M p_{ij}}{\sum_{l=0}^M \sum_{j=0}^M p_{lj}}$ 表示真实类别 i 在整个测试集中出现的像素频率。FWIoU 通过对每个类别的 IoU 值按其像素频率进行加权平均，使得评估结果更能反映模型在实际应用中的表现，特别是在类别分布不均的情况下。

像素精度 (PA) 是最直观的评估指标，计算所有像素中被正确分类的比例：

$$PA = \frac{\sum_{i=0}^M p_{ii}}{\sum_{i=0}^M \sum_{j=0}^M p_{ij}} \quad (4-23)$$

PA 值越高，表明模型的整体分类准确性越好。平均像素精度 (MPA) 进一步考虑了各类别之间的平衡，通过计算每个类别精度的平均值获得：

$$MPA = \frac{1}{M+1} \sum_{i=0}^M \frac{p_{ii}}{\sum_{j=0}^M p_{ij}} \quad (4-24)$$

MPA 值反映了模型在各个类别上的平均分类能力，对少数类别的性能变化更为敏感。

本文采用多维度评估指标与面向类别不平衡的加权交叉熵损失函数，对态势感知模型进行性能评估。该体系能够衡量模型在复杂水下环境中的分割精度与分类能力，并通过损失函数设计引导模型关注少数类别，从而提升其在类别不平衡数据上的整体表现与实际应用效果。

4.4.2 消融实验

为全面评估各输入模态对态势感知性能的贡献，本文设计了一系列消融实验。原始 RGB 图像、深度图与预测差异图共同输入态势感知模块，生成最终的安全评估图。通过系统性地分析不同特征组合的影响，我们旨在深入理解各模态在复杂水下环境中的相对重要性。

不同特征组合下的性能对比如表4-1所示，展示了在多种典型水下场景中的态势感知结果。其中 I 表示原始 RGB 图像， D 表示估计的深度图， P 表示预测差异图。需要说明的是，预测差异图主要作为特征融合过程中的引导辅助信息，未作为独立输入进行评估。




图 4-6 不同特征组合的消融实验结果可视化

Fig. 4-6 Visualization of ablation study results for different feature combinations

从表4-1中可以观察到：单一特征输入的性能均有限，尤其是“警告”类别的 IoU 较低。融合深度信息后，性能显著提升，说明几何距离是判断安全等级的重要依据。进一步加入动态信息后，“警告”类别的 IoU 从 0.55 提升至 0.57，表明动态特征有助于识别潜在风险区域（如摇曳海草的范围）。三者融合取得了最优的综合性能，MIoU 达到 0.77，FWIoU 达到 0.86，PA 达到 0.91。定量结果表明，加入深度图能显著提升性能，特别是在具有复杂空间结构的场景中，而动态差异图的加入进一步增强了模型对动态变化的敏感性。具体来说，与仅使用 RGB 的基线相比，加入深度图使 MPA 平均提高了 6%，加入动态特征又带来了额外的 1% 提升。

图4-6展示了不同特征组合的消融实验结果可视化。从视觉结果中可以明显看出， $I + D + P$ 配置产生最准确和结构一致的结果，与真实标注高度匹配。相比之下，仅依

表 4-1 不同输入特征组合下的态势感知性能对比

Table. 4-1 Performance comparison of situational awareness under different input feature combinations. I represents the raw image, P the difference map, and D the estimated depth map.

输入特征	IoU $\uparrow$			MIoU $\uparrow$	FWIoU $\uparrow$	PA $\uparrow$	MPA $\uparrow$
	危险	警告	安全				
I	0.83	0.51	0.74	0.69	0.79	0.87	0.80
D	0.75	0.33	0.82	0.63	0.75	0.82	0.79
$I + D$	0.88	0.55	0.88	0.77	0.86	0.91	0.86
$I + P$	0.84	0.49	0.87	0.74	0.84	0.89	0.86
$D + P$	0.80	0.41	0.81	0.67	0.79	0.86	0.79
$I + D + P$	0.88	0.57	0.87	0.77	0.86	0.91	0.87

赖单一或两个模态的模型往往表现出不完整的分割或模糊边界，特别是在涉及运动或深度不连续性的区域。

为进一步分析所提方法 ($I + D + P$) 的训练动态，图4-7展示了训练过程中的损失曲线、各类别 IoU 趋势以及验证集 MIoU 的变化情况。随着训练迭代次数的增加，整体 MIoU 和各类别的 IoU 均稳步提升，表明模型能够有效收敛。与其他融合策略相比，所提方法在关键类别上表现出更高的分类精度。




图 4-7 训练过程中各项指标的变化趋势

Fig. 4-7 Training and evaluation metrics over epochs

综合定性与定量分析，本文提出的三模态融合策略 ($I + D + P$) 融合了 RGB 图像的纹理信息、深度图的几何结构信息以及动态差异图的时序变化信息，能够在复杂水下环境中实现态势感知。该多模态融合方法在提升分割精度的同时，增强了对动态变化的敏感性，为水下航行器在未知环境中的安全导航提供了有效支撑。

4.4.3 对比实验

为全面评估所提方法的性能，本文将其与多种主流语义分割网络进行了对比实验，包括 U-Net^[88]、PSPNet^[90]、DeepLabv3+^[91] 和 SegNet^[92]。所有对比方法均在相同的 UVSA 数据集和训练设置下进行评估，以确保公平性。表4-2 展示了各方法的定量性能对比。需要说明的是，为直观展示分割结果与原始场景的对应关系，如图4-8 所示，图中所有展示结果均为原始 RGB 图像与分割图像按照 0.6:0.4 的权重叠加生成的融合图像。

表 4-2 不同方法在 UVSA 数据集上的性能对比

Table. 4-2 Performance comparison of different methods on the UVSA dataset

方法	IoU ↑			MIoU↑	FWIoU↑	PA↑	MPA↑	Params
	危险	警告	安全					
U-Net ^[88]	0.84	0.57	0.85	0.75	0.80	0.88	0.85	26.4M
PSPNet ^[90]	0.92	0.58	0.84	0.77	0.85	0.91	0.86	46.7M
DeepLabv3+ ^[91]	0.72	0.40	0.75	0.62	0.68	0.79	0.78	59.3M
SegNet ^[92]	0.79	0.34	0.79	0.64	0.71	0.83	0.75	29.4M
Ours	0.88	0.57	0.87	0.77	0.86	0.91	0.87	34.7M

从表 4-2 可以看出，所提方法在 UVSA 数据集上整体表现 x 相对较稳定，在多项评价指标上均取得了较为优秀的结果。在平均交并比（MIoU）方面，所提方法达到 0.77，性能与 PSPNet（0.77）相同，但明显优于 DeepLabv3+（0.62）和 SegNet（0.64），表明该方法在整体分割精度与类别均衡性方面具有一定优势。尽管 PSPNet 在危险类别上的 IoU 最高（0.92），但其在安全类别上的分割性能（0.84）低于所提方法（0.87），说明所提方法在不同风险等级语义区域之间具有更加均衡的分割效果。需要指出的是，警告（Warning）类别由于边界模糊且样本数量相对有限，语义区分难度较大，导致各方法在该类别上的 IoU 整体偏低，这一现象也反映了该类别在数据集中的固有挑战性。在频权交并比（FWIoU）指标上，所提方法取得 0.86，优于 U-Net（0.80）和 DeepLabv3+（0.68），进一步体现了其在主要语义区域上的分割稳定性。从模型复杂度角度来看，虽然 U-Net 的参数数量最少（26.4M），但其分割精度相对有限；相比之下，所提方法在参数规模为 34.7M 的情况下，在多项性能指标上均优于 PSPNet 和 DeepLabv3+，在分割精度与模型复杂度之间实现了更为合理的权衡，具有较好的实际应用潜力。

图4-8 直观展示了各方法在五种典型水下场景中的分割效果对比。图中第一行为原始 RGB 图像，第二至第五行分别为 U-Net、PSPNet、DeepLabv3+ 和 SegNet 的分割

结果（均为原始图像与分割结果的 0.6:0.4 加权叠加），第六行为所提方法的分割结果，第七行为真实标注（Ground Truth）。




图 4-8 不同方法在典型水下场景中的分割效果对比

Fig. 4-8 Comparison of segmentation results by different methods in typical underwater scenarios

从定性结果中可以观察到以下现象：DeepLabv3+ 的分割结果存在过平滑现象，在边缘区域产生块状伪影，特别是在场景 (b) 和 (d) 中，珊瑚与背景的交界处分割不连续，导致评估结果有偏差。PSPNet 在场景 (b) 中对珊瑚礁区域的处理存在类别混淆现象，未能将整个珊瑚礁区域正确划分为危险区域，部分区域被错误归类为安全级别；在场景 (d) 中也表现出类似的问题。SegNet 在场景 (e) 中对鱼体边缘的分割出现断裂，连续性不足，且在场景 (d) 的海草区域也表现出分割结果缺乏空间一致性的问题。从可视化结果来看，所提方法与其他方法相比，在部分场景下表现出一定的改进，例如在边缘连续性和类别一致性方面有所提升，在鱼体边缘及海草区域的分割结果中也展现出更强的结构完整性与空间一致性。这些改进表明，所提方法在细节保持与整体结

构的感知理解上取得了较好的平衡，从而在不同的水下场景下均能提供更为可靠与一致的分割感知结果。

所提方法通过引入多尺度特征融合机制和注意力模块，相比于原始的 U-Net 有效提升了模型对细节边界和复杂结构的处理能力，避免了其他方法中出现的过平滑、类别混淆和分割不连续等问题。综合定性与定量分析，所提方法在保持轻量化设计的同时，实现了与主流语义分割网络相当甚至更优的性能，能够满足水下机器人对实时环境感知与安全评估的需求。

4.4.4 实时性分析




图 4-9 不同测试环境下态势感知结果的可视化比较。子图 (a)–(i) 对应于模拟海上环境下的实验结果，展示了模型在不同水下条件下的感知能力；子图 (j)–(r) 对应于青岛近岸水域的实地试验结果，反映了模型在真实水下环境中对多目标及障碍物的态势感知表现

Fig. 4-9 Visual comparison of situational awareness results under different testing environments.

Subfigures (a)–(i) correspond to results from simulated offshore scenarios, while subfigures (j)–(r) present results from field experiments conducted in nearshore waters around Qingdao

在实际的 AUV 系统中，态势感知模块必须在资源受限的嵌入式平台上高效运行，以满足实时控制的需求。为了评估所提 SA-Net（态势感知网络）的实时性能，我们在搭载 Intel Xeon Platinum 8255C CPU (2.50 GHz) 和 NVIDIA GeForce RTX 2080 Ti GPU 的工作站上进行了推理速度测试。测试结果表明，对于单张 480×640 分辨率的 RGB 图像，结合稀疏声纳数据进行深度融合和态势评估，生成带有 SA 标签的语义图，平

均每帧处理时间约为 0.13 秒（约合 7.7 fps）。考虑到态势感知模块通常作为上层规划与控制模块的输入，其输出频率已足以支撑下游的 MPC 控制器（典型控制频率为 5-10 Hz）进行实时路径规划与决策。这一实时性能为 AUV 在动态水下环境中实现实时理解奠定了坚实的基础。此外，SA-Net 的轻量化设计（参数量仅 34.7M）也为其未来部署到 Jetson TX2 等嵌入式 AI 计算平台提供了可能，进一步推动该技术在实际 AUV 系统中应用的可行性。

图4-9 展示了所提态势感知系统在多种测试环境下的代表性输出结果，包括静水室内水池、近岸室外水域以及动态海洋现场条件。子图 (a)-(c) 展示了模拟室内静水场景，仅改变物体类型和相机与目标之间的距离。子图 (d)-(i) 展示了在水下机器人在实验室环境中受控移动的结果，证明了系统在静态水下物体存在下可靠的态势感知能力。子图 (j)-(m) 对应真实世界的近岸部署场景，其中场景中没有明显的静态物体。特别值得注意的是，在子图 (n)-(r) 中，一个移动的螃蟹在子图 (o) 和 (p) 中清晰可见，反映了系统感知和解释海底动态目标的能力。这些结果证明了该模型即使在视觉退化或声学噪声场景下，也能通过声学-光学融合准确检测水下物体、解释空间布局并生成可靠的深度线索。综合而言，该系统的实时处理与感知性能为轻量级 AUV 在复杂真实水下环境中的自主作业提供了支持。

4.5 本章小结

为满足水下航行器对复杂环境的语义理解需求，本章提出一套视觉与 SBES 融合的态势感知方法。该方法以高精度深度感知为基础，设计双分支注意力融合网络，对 RGB 外观、深度几何与动态时序特征进行融合。针对水下场景的动态不确定性与样本分布不均问题，引入时序动态特征模块与加权损失函数，提升模型对风险区域的敏感性和识别稳定性。实验从定量性能、模型对比、消融分析及实时性等方面验证了该方法在像素级安全语义图生成上的有效性。本章工作将前序的几何感知能力提升至语义理解层面，为后续基于环境认知的智能避障决策提供信息输入。

5 基于态势感知的模型预测控制

在第四章中，我们成功构建了基于视觉-SBES 融合的态势感知方法，能够从复杂水下环境中提取像素级的语义安全信息。然而，要将这种高层次的环境认知转化为水下航行器的安全、高效自主行为，仍需要一种能够融合感知信息与控制决策的智能控制框架。传统的避障方法往往将感知与决策分离，基于简单的几何规则或预定义的路径进行反应式避障，在应对水下环境的动态性、不确定性和复杂性方面存在一定局限性。针对轻量级 AUV 在浅水区、河流和湖泊等复杂环境中面临的柔性缠绕障碍物挑战，以及低成本传感器（单波束回声测深仪 SBES 和光学相机）感知信息融合的难题，本章提出一种态势感知驱动模型预测控制框架（SA-MPC）。该框架旨在将前序章节生成的精细态势感知地图（SA-map）和深度信息嵌入控制回路的优化决策过程中，尝试实现“感知-理解-决策-控制”的协同，使 AUV 具备基于环境理解的“风险意识”，从而在复杂动态环境中实现一定程度的自适应避障。

5.1 HoloOcean 仿真平台




图 5-1 HoloOcean 系统架构概览

Fig. 5-1 HoloOcean: An open-source underwater simulator built on Unreal Engine 4 with various underwater sensors

为验证所提框架的性能，本章所有仿真实验均在开源水下仿真环境 HoloOcean 中

进行。HoloOcean 是一款基于 Unreal Engine 4 开发的开源水下机器人仿真器，其系统架构如图5-1 所示。该平台具备水下动力学与传感器仿真、多智能体与通信仿真、Python 接口与环境构建等特性。具体而言，HoloOcean 基于 PhysX 物理引擎实现了水下动力学模型，包括浮力、阻力等效应，同时集成了多种水下常用传感器的仿真模型。平台支持多 AUV 协同任务仿真，并集成了声学调制解调器模型，可模拟水下受限通信环境下的信息交互。此外，平台提供类似 OpenAI Gym 的简洁 Python API，支持快速任务配置与算法部署。作为开源项目，HoloOcean 避免了复杂的依赖项，支持通过 pip 安装，降低了研究人员的入门门槛。




图 5-2 HoloOcean 传感器可视化工具演示

Fig. 5-2 Sensor visualization tools in HoloOcean: (a) optical modem communication, (b) sonar simulation with octree, (c) DVL beam visualization

在传感器仿真方面，HoloOcean 集成了多种水下常用传感器的仿真模型，包括采用基于八叉树的算法生成多波束声纳图像的成像声纳传感器、能够模拟四波束多普勒测速的多普勒计程仪（DVL）、包含时变偏置的角速度与线加速度测量的惯性测量单元（IMU）模型，以及深度传感器、相机、GPS 等多种传感器，均配有可配置的噪声模型。图5-2 展示了 HoloOcean 中各类传感器的可视化效果。在仿真环境构建方面，HoloOcean 提供了多样化的预设水下场景，如图5-3 所示。综上所述，HoloOcean 在仿真保真度、功能完整性、易用性方面能满足本章对水下算法验证的需求，本文所有仿真实验均基于此平台开展。

5.2 SA-MPC 框架

所提出的 SA-MPC 框架是一个集成了环境感知、风险建模与运动优化的闭环系统，如图5-4 所示。整个框架包含三个主要部分：感知层、决策层与执行层。感知层即为第四章所述的态势感知模块，负责从原始传感器数据（单目相机与 SBES）中实时生成深度图与 SA 地图。决策层由一个学习型模型预测控制器（Learning-based MPC）构成。它接收 SA 地图与深度图，将其编码为空间风险势场，并结合一个通过学习得到的 AUV 概率动力学模型，在预测时域内优化未来一系列控制指令。执行层则负责将优化得到的最优控制序列发送给 AUV 的底层执行器。




图 5-3 HoloOcean 预设仿真环境示例

Fig. 5-3 Pre-built simulation environments in HoloOcean: (a) dam environment, (b) pier environment, (c) open water environment




图 5-4 SA-MPC 框架整体架构

Fig. 5-4 Overall architecture of the SA-MPC framework

5.2.1 空间风险势场构建

为将 SA 模块输出的语义地图信息（包含“危险”、“警告”、“安全”三个安全等级）有效融入模型预测控制的优化回路，需将离散的语义标签量化为一个连续可微的空间风险势场 $V_{\text{risk}}(\mathbf{x})$ ，其中 $\mathbf{x} = (x, y, z)$ 代表 AUV 在环境中的三维位置。该势场融合了来自 SA 地图的语义风险与来自深度图的几何接近度风险，其定义如下：

$$V_{\text{risk}}(\mathbf{x}_t) = w_s \cdot \Phi_s(S_t(\mathbf{x}_t)) + w_d \cdot \Phi_d(D_t(\mathbf{x}_t)) \quad (5-1)$$

其中， S_t 为 t 时刻的 SA 地图， D_t 为 t 时刻的提炼深度图。 w_s 和 w_d 为权重系数，用于平衡语义与几何信息的贡献。 $\Phi_s(\cdot)$ 为语义风险势函数，用于将离散的类别标签转化为连续势场； $\Phi_d(\cdot)$ 为几何接近度势函数，基于深度信息惩罚与障碍物的接近程度。

语义势场 $\Phi_s(\cdot)$ 的构建首先通过计算一个“软”距离图，以量化场景中任意像素

点 p 到所有标记为危险或警告区域的综合影响距离：

$$d_{\text{danger}}(p) = -\frac{1}{\gamma} \log \left(\sum_q \exp(-\gamma \cdot \text{dist}(p, q)) \cdot m_{\mathcal{D}}(q) \right) \quad (5-2)$$

此处， $m_{\mathcal{D}}(q)$ 为像素 q 的风险值（危险=1，警告=0.5，安全=0）， $\text{dist}(p, q)$ 为像素 p 与 q 之间的欧氏距离， γ 为控制距离度量锐度的参数。随后，通过一个高斯核函数将此距离映射为势场：

$$\Phi_s(p) = \exp \left(- \left(\frac{d_{\text{danger}}(p)}{\sigma_{\text{sa}}} \right)^2 \right) \quad (5-3)$$

其中， σ_{sa} 控制危险区域影响的扩散范围。此设计使得危险区域核心具有高势场值，其影响随距离增加而平滑衰减，警告区域则产生中等强度的排斥场。

几何势场 $\Phi_d(\cdot)$ 直接基于深度信息构造，采用一个截断线性函数来反映与障碍物的空间接近度：

$$\Phi_d(p) = \text{clip} \left(\frac{z_{\text{safe}} - D_t(p)}{z_{\text{safe}}}, 0, 1 \right) \quad (5-4)$$

式中， z_{safe} 为预设的安全距离阈值， $D_t(p)$ 为深度图中像素 p 对应的距离值。当 AUV 与最近障碍物的估计距离 $D_t(p)$ 小于安全阈值 z_{safe} 时，此项产生正向成本，且距离越近成本越高。

最终，构建的空间风险势场 V_{risk} 被嵌入 MPC 的优化目标函数中，与轨迹跟踪误差、控制输入能量以及模型预测不确定性等项共同构成完整的代价函数，引导 AUV 在复杂水下环境中实现安全、平滑且节能的避障控制。

5.2.2 学习型概率动力学模型

由于水下流体动力学复杂且存在不确定性，我们采用一个概率多层感知机 (Probabilistic MLP) 来学习 AUV 的状态转移函数。该网络以当前状态向量 $\mathbf{x}_t$ 和控制输入 $\mathbf{u}_t$ 为输入，预测下一时刻状态的均值 μ_{t+1} 和方差 σ_{t+1}^2 ：

$$[\mu_{t+1}, \log \sigma_{t+1}^2] = f_{\theta}(\mathbf{x}_t, \mathbf{u}_t) \quad (5-5)$$

其中状态向量 $\mathbf{x}_t$ 包含 AUV 的位置、姿态、线速度和角速度，共 12 维；控制输入 $\mathbf{u}_t$ 由八个推进器的推力标度组成。该概率 MLP 网络由三个全连接隐藏层构成，每层 256 个神经元，使用 ReLU 激活函数。训练数据在仿真环境 HoloOcean 中采集，覆盖各种水流扰动工况，通过随机采样的方式收集状态转移数据。模型通过最小化观测数据的负对数似然进行训练：

$$\mathcal{L}_{NLL}(\theta) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^{n_x} \left[\frac{(x_{t+1,j}^{(i)} - \mu_{t+1,j}^{(i)})^2}{\sigma_{t+1,j}^{(i)}} + \log \sigma_{t+1,j}^{2(i)} \right] \quad (5-6)$$

其中 N 为训练样本数, $n_x = 12$ 为状态维度。在 MPC 预测中, 均值 μ 用于状态预测, 而预测方差 σ^2 则作为一项额外成本被引入优化问题, 尝试鼓励控制器选择动力学预测更确定 (不确定性低) 的动作, 从而在随机水流扰动下提高安全性。这种概率建模方式尝试使控制器能够区分不同工况下的预测置信度: 在平稳水流区域, 模型方差较小, 控制器可进行更激进的操作; 而在强扰动区域, 模型方差增大, 控制器将采取更保守的避障策略。

总的来说, 动力学模型的构建过程主要包括以下几个关键步骤: 首先, 在 HoloOcean 仿真环境中设置不同的水流条件; 其次, 通过随机控制策略采集 AUV 在不同初始状态和控制输入下的状态转移数据; 然后, 再对采集的数据进行预处理; 最后, 使用处理过后的数据训练概率 MLP 网络。在训练过程中, 我们采用早停策略以防止过拟合, 并通过验证集监控模型的性能。

5.2.3 模型预测控制器

MPC 控制器在每个控制周期求解一个有限时域 H 内的优化问题, 以获得最优控制序列 $\mathbf{U}^* = [\mathbf{u}_t, \mathbf{u}_{t+1}, \dots, \mathbf{u}_{t+H-1}]$ 。其成本函数 J 集成了目标跟踪、控制效率、风险规避与模型不确定性惩罚:

$$\begin{aligned} \min_{\mathbf{U}} J = & \sum_{k=0}^{H-1} \left[\alpha_1 \|\mathbf{x}_{t+k+1} - \mathbf{x}_{\text{goal}}\|^2 + \alpha_2 \|\mathbf{u}_{t+k}\|^2 + \alpha_3 V_{\text{risk}}(\mathbf{x}_{t+k+1}) + \alpha_4 \cdot \text{tr}(\sigma_{t+k+1}^2) \right] \\ & + \sum_{k=0}^{H-2} \left[\beta \|\mathbf{u}_{t+k+1} - \mathbf{u}_{t+k}\|^2 \right] \end{aligned} \quad (5-7)$$

约束条件为:

$$\mathbf{x}_{t+k+1} = f_{\theta}(\mathbf{x}_{t+k}, \mathbf{u}_{t+k}) \quad (5-8)$$

$$\mathbf{u}_{\min} \leq \mathbf{u}_{t+k} \leq \mathbf{u}_{\max} \quad (5-9)$$

其中:

- $\alpha_1 = 15.0$: 目标跟踪权重, 确保航行器朝着目标位置前进
- $\alpha_2 = 0.001$: 控制效率权重, 避免过大的控制输入
- $\alpha_3 = 80.0$: 风险规避权重, 将前文构建的风险势场融入优化过程
- $\alpha_4 = 0.3$: 模型不确定性惩罚权重, 鼓励选择动力学预测更确定的动作
- $\beta = 0.1$: 控制平滑度权重, 确保控制指令的变化平缓

式 (5-7) 中各项的物理意义明确：第一项为目标跟踪项，确保航行器朝着目标位置前进；第二项为控制效率项，避免过大的控制输入；第三项为风险规避项，将前文构建的风险势场融入优化过程；第四项为模型不确定性惩罚项，鼓励控制器选择动力学预测更确定的动作；第五项为控制平滑度项，确保控制指令的变化平缓，提高系统的稳定性和执行器的寿命。

由于势场与动力学模型均可微，采用基于梯度的优化算法求解。控制器利用自动微分技术计算成本函数梯度 $\frac{\partial J}{\partial \mathbf{U}_{0:H-1}}$ ，并使用 Adam 优化器进行迭代更新。为了提升优化效率，采用热启动策略：将上一控制周期的最优控制序列向后平移一位，作为当前周期优化问题的初始猜测，从而减少收敛所需迭代次数。控制输入被约束在推力器物理限制范围内，通过投影操作确保可行性。

每次优化完成后，仅执行最优控制序列中的第一个控制量 $\mathbf{u}_t^*$ ，并在下一控制周期重新进行滚动优化。这种重复规划的策略使控制器能够应对环境变化和感知更新，为水下自主航行提供了一种技术方案。

5.3 实验与分析

5.3.1 学习型动力学模型验证

为构建一个能够反映 AUV 在扰动环境下动态特性的预测模型，我们在高保真的 HoloOcean 仿真环境中开展了数据采集与模型训练工作。该概率动力学模型是后续 SA-MPC 控制器的组成部分，其预测准确性及不确定性量化能力影响控制器在复杂流场中进行规划与决策的性能。选择该仿真环境的原因在于其能够模拟水下流体动力学效应，并允许我们以可控的方式注入多种水流扰动，从而生成涵盖广泛动态工况的数据集。该数据集是后续训练能够表征不确定性的概率动力学模型的基础。

表5-1 列出了用于生成训练数据的水流扰动配置。其中，环境水流速度 v_{flow} 与方向 θ_{flow} 模拟了水平面内变化的环境流场；垂向水流 $v_{z,\text{flow}}$ 与低频变化 f_{flow} 则引入了垂直方向的非稳态扰动；而时间波动项 ϵ_{flow} 作为高斯白噪声，模拟了难以建模的高频随机干扰。这种多维度、宽范围的扰动配置，旨在使学习模型捕获 AUV 在复杂流场中的核心动力学特性及其不确定性。

基于此数据集，我们训练了一个概率性多层感知机（Probabilistic MLP）来近似 AUV 的状态转移函数。该网络不仅预测下一时刻状态的均值 μ_{t+1} ，还同时输出一个状态依赖的方差 σ_{t+1}^2 ，从而对预测本身的不确定性进行量化。模型通过最小化负对数似然损失进行训练，该损失函数鼓励模型在预测不准时给出更大的方差。

训练完成后，我们从整体预测趋势上评估模型的性能。图5-5 展示了概率模型与一个确定性基线模型在长达 50 步的预测时域内，其累积预测误差的演变情况。可以

表 5-1 水流扰动配置参数

Table. 5-1 Water flow disturbance configuration parameters

符号	描述	采样范围/设置
v_{flow}	环境水流速度	0.0-0.5 m/s
θ_{flow}	相对于世界 X 轴的方向	0° - 360° (均匀分布)
$v_{z,\text{flow}}$	向上或向下的水流	-0.1-0.1 m/s
ϵ_{flow}	时间波动项 (高频噪声)	$\mathcal{N}(0, 0.02)$
f_{flow}	低频水流变化频率	0.1-1.0 Hz

看出，概率模型在大部分预测步长上优于确定性模型。随着预测时域的延长，确定性模型的误差累积较快，而概率模型的误差增长则相对平缓。这验证了概率模型通过显式建模不确定性，获得了相对更好的长期预测能力。其输出的方差（图中阴影区）也反映了预测置信度随时间下降的趋势。




图 5-5 预测误差随预测时域的变化曲线

Fig. 5-5 Prediction error curves with respect to the prediction horizon

为了深入理解模型在不同运动维度上的表现差异，我们进一步将预测误差分解到各个状态维度进行分析，结果如图5-6所示。分析表明，对于位置 (x, y, z) 、大部分姿态角及线速度等维度，概率模型实现了较高的预测精度。然而，在滚转角 (roll) 维度上，两种模型的预测误差均显著高于其他状态。这一现象揭示了所选用 ROV 平台的一个动力学特性：由于其结构设计及推力器布局，在绕纵轴 (roll) 方向的转动惯量较小，且执行器在该自由度上的控制权限和抗扰动能力相对有限，导致其运动更容易受到垂直方向水流扰动的显著影响，因而更难以准确预测。尽管如此，在此具有挑战性的维度上，概率模型依然表现出了相对于确定性模型的一定优势。




图 5-6 不同状态维度的预测误差

Fig. 5-6 Prediction errors across different state dimensions

最后，我们通过一个具体的轨迹预测案例来对比两种模型的性能。图5-7展示了一段包含机动变化的真实 AUV 轨迹，以及两种模型基于初始状态进行的多步开环预测。可以观察到，概率模型预测的轨迹在大部分空间维度上与真实轨迹贴合得相对紧密。而确定性模型的预测轨迹则随着时间推移逐渐发散，尤其在垂直（ z ）方向上产生了明显的漂移。这个对比表明，概率动力学模型不仅提供了不确定性的度量，其均值预测本身也因融合了不确定性信息而更加准确。

综上所述，本节的实验表明所学习的概率动力学模型能够在一定程度上拟合 AUV 的动态特性，并量化由水流扰动等因素引起的预测不确定性。该模型在长时域预测精度和对挑战性运动维度的建模能力上优于传统的确定性模型。该模型输出的状态预测均值与方差，将作为后续 SA-MPC 控制器进行滚动优化时系统动态约束与风险认知的输入，为轨迹优化提供参考。

5.3.2 避障性能仿真对比实验

在验证了学习型动力学模型的有效性之后，我们对集成该概率模型的 SA-MPC 框架的整体避障性能进行了仿真评估。该实验旨在检验融合了不确定性动态预测与语义风险势场的 SA-MPC 控制器在实际复杂障碍场景下的表现，特别是其在面对静态刚性障碍、柔性缠绕物以及动态移动目标时的决策表现。实验设置模拟真实作业场景：




图 5-7 概率与确定性模型的轨迹预测对比

Fig. 5-7 Comparison of trajectory prediction between probabilistic and deterministic models

AUV 仅被赋予一个三维空间中的目标点坐标，而没有任何预先构建的环境地图。这一设定使得航行器必须依赖实时感知和在线决策来完成自主导航。

图5-8 展示了 SA 模型部署到 HoloOcean 仿真环境中的实际运行界面。图中上方从左至右依次为单目相机拍摄的 RGB 图像、对应的深度估计图以及生成的态势感知图，下方为仿真环境的整体视图，其中可以观察到装备在 AUV 上的单波束回声测深仪 (SBES) 的测量数据可视化。该配置直观展示了从原始传感器数据到高层次环境理解的完整处理流程，验证了 SA 模型在仿真环境中的有效集成。

仿真实验的具体配置如表5-2 所示。该配置使用 HoveringAUV 作为基础平台，集成了位姿传感器、速度传感器、IMU、DVL、深度传感器、单波束声纳以及 RGB 相机等多种传感器。其中，单波束声纳的配置参数为：距离分辨单元 20 个，方位角分辨单元 128 个，最小探测距离 0.01m，最大探测距离 15m，波束开角 30° （俯仰和方位），并启用视锥区域可视化。RGB 相机的分辨率为 640×480 像素，帧率为 5Hz。仿真环境设置为 OpenWater 场景，包含六个 AUV 智能体，其中 auv0 为主控航行器，auv1 为目标点，auv2 至 auv5 为四个障碍物。

为了对比分析，我们将其与经典的基于全局规划的 A* 算法结合 path-follow 的方法进行了对比。后者代表着当前主流的导航范式，即在已知静态障碍物分布的情况下，通过 A* 算法规划一条全局最优路径，再精确跟踪该路径。这种方法的局限性在于其强依赖于精确的静态环境先验，无法适应动态变化或包含柔性未知障碍的场景。相比之下，SA-MPC 完全基于实时采集的视觉和声纳数据构建态势感知，并将语义化的风险信息直接融入滚动优化过程，尝试实现无先验地图下的在线自适应导航。

表 5-2 HoloOcean 仿真环境关键配置参数

Table. 5-2 Key configuration parameters of HoloOcean simulation environment

配置项	参数设置
仿真名称	HoveringCamera
仿真世界	OpenWater
主智能体	auv0
仿真频率	200 ticks/sec
启用帧率限制	是
八叉树最小分辨率	0.02 m
八叉树最大分辨率	5.0 m
窗口尺寸	1280×720 pixels
主控航行器 (auv0)	
类型	HoveringAUV
位置	[35.0, -40.5, -292.5] m
朝向	[0.0, 0.0, 89.0]°
传感器配置	• PoseSensor (位姿传感器) • LocationSensor (位置传感器) • VelocitySensor (速度传感器) • IMUSensor (200Hz, 含噪声配置) • GPSSensor (5Hz, Sigma=0.5)
	• DVLSensor (20Hz, 仰角 22.5°, 测速标准差 0.02626) • DepthSensor (100Hz, Sigma=0.255) • SinglebeamSonar (10Hz, 20 距离单元 ×128 方位单元, 0.01-15m, 30°×30° 波束) • RGBCamera (5Hz, 640×480 分辨率)
目标点 (auv1)	
类型	HoveringAUV
位置	[35.36, -20.95, -292.5] m
朝向	[0.0, 0.0, -50.0]°
障碍物 (auv2-auv5)	
类型	HoveringAUV
位置	auv2: [35.5, -35.0, -291.0] m
	auv3: [34.7, -30.0, -294.0] m
	auv4: [35.9, -25.5, -291.5] m
	auv5: [35.9, -25.5, -293.5] m




图 5-8 SA 模型在 HoloOcean 仿真环境中的部署

Fig. 5-8 Deployment of the SA model in HoloOcean simulator: Top row displays (from left to right) the RGB image from monocular camera, corresponding depth estimation map, and generated situational awareness map; bottom shows the overall simulation environment with SBES measurements visualization.

仿真实验在 HoloOcean 平台中构建了一个综合性的水下测试场景，如图5-9 所示。该场景设计了多种类型的障碍物以模拟真实水下环境的复杂性：静态的礁石和沉船残骸构成了刚性障碍；摇曳的海藻和悬浮的渔网模拟了柔性缠绕物；数个自主移动的其他 ROV 则作为动态障碍物在场景中随机巡游。图中红色圆圈标出了当前正在执行任务的受控 AUV。这种多元化的障碍配置旨在测试算法在不同风险维度上的应对能力。

从图5-9 (b) 所示的避障轨迹对比中可以观察到两种方法在行为逻辑上的差异。 A^* +path-follow 方法产生的轨迹严格遵循预先计算的全局最优路径，这种路径通常是在忽略动态障碍和风险语义的情况下规划出的几何最短路径。如图所示，该轨迹紧贴静态障碍边缘行进，在通过海藻区时也选择直接穿越，对移动的 ROV 只能做出被动的局部避让。这种策略虽然理论上高效，但在实际中可能存在安全隐患，特别是在面对柔性障碍时可能引发缠绕风险。

SA-MPC 框架则尝试表现出更安全的导航行为。其生成的轨迹整体较为平滑，在安全性和效率之间寻求平衡。具体表现为：在路径选择上尝试规避被标记为“危险”




图 5-9 仿真环境与避障轨迹对比

Fig. 5-9 The simulation environment, with the active ROV highlighted in red circle. (a) A representative test scenario. (b) The corresponding trajectory.

的区域，与障碍物保持了相对较大的安全距离；对柔性障碍表现出一定的“警惕性”，在面对海藻区时尝试规划绕行路径而非直接穿越；尝试对动态障碍物的未来位置做出预测，提前调整轨迹以避免潜在的冲突。这些行为特征源于 SA-MPC 将实时态势感知融入了控制优化过程，使得 AUV 不仅能够感知障碍物，还能考虑不同类型障碍物的风险特性。

为了对两种方法的性能进行量化评估，我们在测试场景中进行了统计实验，平均得到的结果汇总于表5-3。从数据中可以发现，SA-MPC 在四个关键指标上表现出一定的优势。在路径效率方面，SA-MPC 的平均路径长度为 20.20 米，比 A*+path-follow 的 24.96 米缩短了约 19.1%。这一结果可能与语义化风险评估有关——SA-MPC 能够识别出哪些区域虽然几何上可通过但风险较高，从而选择更安全但整体更高效的通行路径。

在能量消耗方面，SA-MPC 的 5213.26 单位对比方法的 5681.15 单位降低了 8.2%。这主要得益于两方面因素：一是更短的路径减少了推进所需的能量；二是更平滑的轨迹避免了频繁的急转机动，减少了由额外加速和制动带来的能量损耗。在安全性指标上，SA-MPC 与最近障碍物的平均距离达到 1.72 米，比 A*+path-follow 的 1.50 米提高了 14.7%，这一改进对于水下作业的安全性具有意义。在执行效率方面，SA-MPC 以 2263 个控制步完成了导航任务，相比对比方法的 2739 步减少了 17.4%。

SA-MPC 的性能提升可能源于其架构设计。传统方法将环境感知与运动规划解耦处理，先由感知模块识别障碍物，再由规划模块计算避障路径，这种串行架构难以处

表 5-3 仿真环境中导航算法的性能指标

Table. 5-3 Performance Metrics of Navigation Algorithms in Simulation Environment

算法	路径长度 (m) ↓	能量消耗 ↓	最近障碍距离 (m) ↑	控制步数 ↓
A* + path-follow	24.96	5681.15	1.50	2739
SA-MPC	20.20	5213.26	1.72	2263

理复杂的语义信息和动态变化。SA-MPC 则通过将态势感知直接嵌入 MPC 的优化目标中，尝试实现感知与决策的融合。具体而言，空间风险势场将不同区域的安全等级量化为连续可微的代价函数，使得控制器在优化过程中不仅考虑几何约束，还能尝试规避高风险区域。这种基于语义理解的规划方式，使得 AUV 能够考虑哪些区域虽然几何上可通过但实际操作风险较高，从而尝试做出更加明智的路径选择。

进一步分析可以发现，SA-MPC 的优势在动态和柔性障碍场景中可能更为明显。对于动态障碍物，传统反应式方法只能在碰撞即将发生时进行紧急避让，而 SA-MPC 则能够基于当前观测尝试预测障碍物的未来运动趋势，提前调整轨迹以避免潜在冲突。对于柔性障碍，传统方法往往难以有效处理，因为这类障碍在几何上可能并不构成直接碰撞威胁，但却有引发缠绕的风险。SA-MPC 通过态势感知模块将这些区域标记为“警告”或“危险”区域，在控制优化中对其施加一定的排斥势场，从而尝试实现针对性的规避。

需要指出的是，这些实验结果是在仿真环境下取得的，实际应用效果可能受到多种因素影响。SA-MPC 框架在处理动态和柔性障碍场景中具有一定的潜力，但对于完全未知的动态障碍物，其预测能力仍有限制。综合来看，SA-MPC 框架在复杂水下避障任务中表现出一定的应用价值。它不仅继承了传统 MPC 在处理系统动力学约束方面的优势，更重要的是通过融合实时态势感知，尝试赋予 AUV 对环境的理解能力。这种方法跳出了传统导航框架将环境简化为二值障碍地图的局限性，而是将语义信息转化为控制语言，使得 AUV 能够在无先验地图的情况下尝试实现安全、高效的自主导航。实验结果表明，这种感知与决策耦合的架构，为轻量级 AUV 在真实复杂水下环境中的作业提供了一种技术参考，可作为实际应用中的辅助决策工具。

5.4 本章小结

本章提出了一种态势感知驱动的模式预测控制（SA-MPC）框架，尝试实现水下航行器在复杂动态环境中的辅助避障。该框架通过构建融合语义与几何信息的空间风险势场，并将其嵌入 MPC 的滚动优化过程，使低层运动控制具备一定的环境理解

能力。为验证框架的有效性，本章基于水下仿真平台 HoloOcean 开展了学习型动力学模型训练与避障性能对比仿真实验。实验结果表明，相较于传统 A* 路径跟踪方法，SA-MPC 能够规划出相对更安全、平滑的轨迹，体现了其将”感知”与”决策”融合潜力。该框架为水下自主系统的智能决策提供了一种技术思路，可在实际作业中作为操作员的辅助决策工具，需在实际环境中进一步验证和完善。

6 结论与展望

6.1 结论

本文针对轻量化 AUV 在复杂水下环境中的避障需求，解决了三个问题：单目视觉尺度模糊、环境风险语义理解不足、感知与控制脱节。具体提出了视觉-声呐深度融合深度估计、像素级态势感知、以及 SA-MPC 控制框架。

本文研究的主要贡献体现在以下三个方面。在感知层面，针对单目视觉深度估计固有的尺度模糊问题，提出了视觉与单波束回声测深仪的深度融合方法。通过残差高斯扩散机制实现了稀疏绝对深度测量向稠密视觉深度图的传播，在保证高空间分辨率的同时恢复了几何尺度，为后续的环境理解奠定了感知基础。

在理解层面，针对轻量化 AUV 的传感器配置，构建了基于时空语义推理的态势感知模型。该模型通过多源信息融合与分层特征提取，实现了对复杂水下场景中不同风险等级区域的像素级语义分割，不仅能识别静态障碍物，更能有效感知柔性缠绕物及动态目标，使系统在视觉退化情况下仍能稳定完成环境识别。

在决策控制层面，提出了态势感知驱动模型预测控制框架，将态势感知输出直接作为 MPC 的优化输入。通过将语义安全地图编码为连续可微的空间风险势场并嵌入 MPC 的滚动优化过程，使控制器能提前规避预测的高风险区域。结合数据驱动的概率动力学模型，在仿真中表现出更好的扰动适应能力。

通过仿真与真实环境的系统验证，上述技术框架展现出了相较于传统方法的综合性能优势。整套解决方案为资源受限的轻量级水下航行器提供了一种可行的自主避障思路，对其在开放水域复杂场景中的工程化应用具有一定的理论价值与实践意义。

6.2 展望

本研究虽然在基于多模态融合与态势感知的水下自主避障方面取得了阶段性进展，但受研究周期与实验条件所限，仍有若干方向值得在未来工作中进一步完善与拓展，当前工作在以下三方面有待深入。

首先，在面向真实水下环境的系统验证与优化方面，当前研究成果已在仿真和有限真实场景中得到初步验证，然而真实水下环境的复杂性和不确定性远超可控实验条件。后续工作需将整套系统部署于实际 AUV 平台，在湖泊、近海等开放水域开展长时间、大范围的航行测试，重点评估视觉-声呐融合感知在浑浊、低照度等极端条件下

的鲁棒性，以及 SA-MPC 控制器在真实海流扰动下的适应能力与实时性。

其次，在动态障碍物的轨迹预测与主动避障方面，本文的态势感知模块主要基于当前时刻的环境状态进行风险评估，对动态障碍物的运动趋势预测能力尚有提升空间。未来可引入时序建模与运动学约束，实现对移动目标（如鱼群、其他航行器）的轨迹预测与行为理解，并将预测信息融入风险势场的构建中，从而增强系统对动态威胁的前瞻性规避能力。

最后，在丰富测试场景与推进多模态传感器融合研究方面，目前研究已在受控环境与部分近岸场景中得到验证，未来需在更广泛、更复杂的水下环境（如河口、养殖区、水下结构物周围）中进行系统性测试，以全面评估系统的泛化能力与适应性。同时，可探索引入更多类型的传感器，如多波束成像声呐或水下激光扫描仪，研究它们与视觉-SBES 系统的深度融合方法，构建更鲁棒、更全面的环境感知体系，以应对极端浑浊、完全黑暗等更具挑战性的作业条件。

水下自主系统的智能化是一个长期且充满挑战的研究方向，期望本工作在深度-语义融合感知方面能为后续研究提供参考。

参考文献

- [1] 徐玉如, 苏玉民. 关于发展智能水下机器人技术的思考[J]. 舰船科学技术, 2008, 30(4):17-21.
- [2] Yu R, Shi Z, Huang C, et al. Deep reinforcement learning based optimal trajectory tracking control of autonomous underwater vehicle[C]//2017 36th Chinese control conference (CCC). IEEE, 2017: 4958-4965.
- [3] Chiang J Y, Chen Y C. Underwater image enhancement by wavelength compensation and dehazing [J]. IEEE transactions on image processing, 2011, 21(4):1756-1769.
- [4] Galdran A, Pardo D, Picón A, et al. Automatic red-channel underwater image restoration[J]. Journal of Visual Communication and Image Representation, 2015, 26:132-145.
- [5] Peng Y T, Cao K, Cosman P C. Generalization of the dark channel prior for single image restoration [J]. IEEE Transactions on Image Processing, 2018, 27(6):2856-2868.
- [6] Wang N, Zheng H, Zheng B. Underwater image restoration via maximum attenuation identification [J]. IEEE Access, 2017, 5:18941-18952.
- [7] Raihan A J, Abas P E, De Silva L C. Depth estimation for underwater images from single view image [J]. IET Image Processing, 2020, 14(16):4188-4197.
- [8] Drews P, Nascimento E, Moraes F, et al. Transmission estimation in underwater single images[C]//Proceedings of the IEEE international conference on computer vision workshops. 2013: 825-830.
- [9] Peng Y T, Cosman P C. Underwater image restoration based on image blurriness and light absorption [J]. IEEE transactions on image processing, 2017, 26(4):1579-1594.
- [10] Berman D, Levy D, Avidan S, et al. Underwater single image color restoration using haze-lines and a new quantitative dataset[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43(8):2822-2837.
- [11] Yu B, Wu J, Islam M J. Udepth: Fast monocular depth estimation for visually-guided underwater robots[C]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3116-3123.
- [12] Eigen D, Puhrsch C, Fergus R. Depth map prediction from a single image using a multi-scale deep network[J]. Advances in neural information processing systems, 2014, 27.
- [13] Laina I, Rupprecht C, Belagiannis V, et al. Deeper depth prediction with fully convolutional residual networks[C]//2016 Fourth international conference on 3D vision (3DV). IEEE, 2016: 239-248.
- [14] Cao Y, Wu Z, Shen C. Estimating depth from monocular images as classification using deep fully convolutional residual networks[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 28(11):3174-3182.
- [15] Bhat S F, Alhashim I, Wonka P. Adabins: Depth estimation using adaptive bins[C]//Proceedings of

- the IEEE/CVF conference on computer vision and pattern recognition. 2021: 4009-4018.
- [16] Garg R, Bg V K, Carneiro G, et al. Unsupervised cnn for single view depth estimation: Geometry to the rescue[C]//European conference on computer vision. Springer, 2016: 740-756.
- [17] Godard C, Mac Aodha O, Brostow G J. Unsupervised monocular depth estimation with left-right consistency[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 270-279.
- [18] Zhou T, Brown M, Snavely N, et al. Unsupervised learning of depth and ego-motion from video[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1851-1858.
- [19] Wang C, Buenaposada J M, Zhu R, et al. Learning depth from monocular videos using direct methods [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 2022-2030.
- [20] Ranjan A, Jampani V, Balles L, et al. Competitive collaboration: Joint unsupervised learning of depth, camera motion, optical flow and motion segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 12240-12249.
- [21] Ebner L, Billings G, Williams S. Metrically scaled monocular depth estimation through sparse priors for underwater robots[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 3751-3757.
- [22] Hu S, Liu Q. Fast underwater scene reconstruction using multi-view stereo and physical imaging[J]. Neural Networks, 2025:107568.
- [23] Bhat S F, Birkel R, Wofk D, et al. Zoedepth: Zero-shot transfer by combining relative and metric depth[J]. arXiv preprint arXiv:2302.12288, 2023.
- [24] Yang L, Kang B, Huang Z, et al. Depth anything: Unleashing the power of large-scale unlabeled data [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 10371-10381.
- [25] Park J, Joo K, Hu Z, et al. Non-local spatial propagation network for depth completion[C]//Computer Vision—ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XIII 16. Springer, 2020: 120-136.
- [26] Zhang Y, Tan J, Zeng Z, et al. Monocular camera and imu integration for indoor position estimation [C]//2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society. IEEE, 2014: 1198-1201.
- [27] Feng Z, Jing L, Yin P, et al. Advancing self-supervised monocular depth learning with sparse lidar [C]//Conference on Robot Learning. PMLR, 2022: 685-694.
- [28] Roznere M, Li A Q. Underwater monocular image depth estimation using single-beam echosounder [C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE,

- 2020: 1785-1790.
- [29] Azarewicz J, Fala G, Heithecker C. Template-based multi-agent plan recognition for tactical situation assessment[C]//Proceedings The Fifth Conference on Artificial Intelligence Applications. IEEE Computer Society, 1989: 247-248.
- [30] Endsley M R. Toward a theory of situation awareness in dynamic systems[J]. Human factors, 1995, 37(1):32-64.
- [31] Murphy R R. Human-robot interaction in rescue robotics[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 2004, 34(2):138-153.
- [32] Morales C, Moral S. Modeling aircrew information management for estimation of situational awareness using dynamic bayesian networks[J]. Simulation Modelling Practice and Theory, 2016, 65: 93-103.
- [33] Munir A, Aved A, Blasch E. Situational awareness: techniques, challenges, and prospects[J]. AI, 2022, 3(1):55-77.
- [34] Massimi F, Ferrara P, Benedetto F. Deep learning methods for space situational awareness in mega-constellations satellite-based internet of things networks[J]. Sensors, 2022, 23(1):124.
- [35] Ferri G, Grasso R, Faggiani A, et al. A hybrid robotic network for maritime situational awareness: Results from the infore22 sea trial[C]//OCEANS 2022, Hampton Roads. IEEE, 2022: 1-10.
- [36] Jeong M, Chadda A, Ren Z, et al. Multi-modal perception dataset of in-water objects for autonomous surface vehicles[J]. arXiv preprint arXiv:2404.18411, 2024.
- [37] Horgan J, Toal D, Ridao P, et al. Real-time vision based auv navigation system using a complementary sensor suite[J]. IFAC Proceedings Volumes, 2007, 40(17):373-378.
- [38] Miguelanez E, Patron P, Brown K E, et al. Semantic knowledge-based framework to improve the situation awareness of autonomous underwater vehicles[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 23(5):759-773.
- [39] Yin L, Chen D, Gu H, et al. Studies on situation reasoning approach of autonomous underwater vehicle under uncertain environment[J]. CAAI Transactions on Intelligence Technology, 2021, 6(2): 235-250.
- [40] Salam T, Edwards V, Hsieh M A. Learning and leveraging features in flow-like environments to improve situational awareness[J]. IEEE Robotics and Automation Letters, 2022, 7(2):2071-2078.
- [41] Rodríguez-Teiles F G, Pérez-Alcocer R, Maldonado-Ramírez A, et al. Vision-based reactive autonomous navigation with obstacle avoidance: Towards a non-invasive and cautious exploration of marine habitat[C]//2014 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2014: 3813-3818.
- [42] Drews P, Hernández E, Elfes A, et al. Real-time monocular obstacle avoidance using underwater

- dark channel prior[C]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2016: 4672-4677.
- [43] Arain B, Dayoub F, Rigby P, et al. Close-proximity underwater terrain mapping using learning-based coarse range estimation[J]. arXiv preprint arXiv:2001.00330, 2020.
- [44] Miguelanez E, Patron P, Brown K E, et al. Semantic knowledge-based framework to improve the situation awareness of autonomous underwater vehicles[J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 23(5):759-773.
- [45] Igonin D M, Kolganov P A, Tiumentsev Y V. Semantic image segmentation as a tool for situational awareness in unmanned vehicle control tasks[C]//Advances in Neural Computation, Machine Learning, and Cognitive Research V: Selected Papers from the XXIII International Conference on Neuroinformatics, October 18-22, 2021, Moscow, Russia. Springer, 2022: 308-318.
- [46] Islam M J, Edge C, Xiao Y, et al. Semantic segmentation of underwater imagery: Dataset and benchmark[C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 1769-1776.
- [47] Waszak M, Cardaillac A, Elvesæter B, et al. Semantic segmentation in underwater ship inspections: Benchmark and data set[J]. IEEE Journal of Oceanic Engineering, 2022, 48(2):462-473.
- [48] Liu F, Fang M. Semantic segmentation of underwater images based on improved deeplab[J]. Journal of Marine Science and Engineering, 2020, 8(3):188.
- [49] Hoy M, Matveev A S, Savkin A V. Algorithms for collision-free navigation of mobile robots in complex cluttered environments: a survey[J]. Robotica, 2015, 33(3):463-497.
- [50] Brooks R. A robust layered control system for a mobile robot[J]. IEEE journal on robotics and automation, 2003, 2(1):14-23.
- [51] Borenstein J, Koren Y. Real-time obstacle avoidance for fast mobile robots[J]. IEEE Transactions on systems, Man, and Cybernetics, 1989, 19(5):1179-1187.
- [52] Rawlings J B, Muske K R. The stability of constrained receding horizon control[J]. IEEE transactions on automatic control, 2002, 38(10):1512-1516.
- [53] Zhang T, Kahn G, Levine S, et al. Learning deep control policies for autonomous aerial vehicles with mpc-guided policy search[C]//2016 IEEE international conference on robotics and automation (ICRA). IEEE, 2016: 528-535.
- [54] Williams G, Wagener N, Goldfain B, et al. Information theoretic mpc for model-based reinforcement learning[C]//2017 IEEE international conference on robotics and automation (ICRA). IEEE, 2017: 1714-1721.
- [55] Nguyen K, Schoedel S, Alavilli A, et al. Tinympc: Model-predictive control on resource-constrained microcontrollers[C]//2024 IEEE International Conference on Robotics and Automation (ICRA).

- IEEE, 2024: 1-7.
- [56] Falcone P, Borrelli F, Asgari J, et al. Predictive active steering control for autonomous vehicle systems [J]. IEEE Transactions on control systems technology, 2007, 15(3):566-580.
- [57] Qi X, Zhang L, Wang P, et al. Learning-based mpc for autonomous motion planning at freeway off-ramp diverging[J]. IEEE Transactions on Intelligent Vehicles, 2024.
- [58] Katara P, Harish Y, Pandya H, et al. Deepmpcv: Deep model predictive control for visual servoing [C]//Conference on Robot Learning. PMLR, 2021: 2006-2015.
- [59] Endsley M R. Toward a theory of situation awareness in dynamic systems[M]//Situational awareness. Routledge, 2017: 9-42.
- [60] Braginsky B, Guterman H. Obstacle avoidance approaches for autonomous underwater vehicle: Simulation and experimental results[J]. IEEE Journal of oceanic engineering, 2016, 41(4):882-892.
- [61] Maurelli F, Krupiński S, Xiang X, et al. Auv localisation: a review of passive and active techniques [J]. International Journal of Intelligent Robotics and Applications, 2022, 6(2):246-269.
- [62] Aubard M, Madureira A, Teixeira L, et al. Sonar-based deep learning in underwater robotics: Overview, robustness, and challenges[J]. IEEE Journal of Oceanic Engineering, 2025.
- [63] Vedachalam N, Ramesh R, Jyothi V B N, et al. Autonomous underwater vehicles-challenging developments and technological maturity towards strategic swarm robotics systems[J]. Marine Georesources & Geotechnology, 2019, 37(5):525-538.
- [64] Randall Y. Flsea: Underwater visual-inertial and stereo-vision forward-looking datasets[D]. University of Haifa (Israel), 2023.
- [65] Akkaynak D, Treibitz T. Sea-thru: A method for removing water from underwater images[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 1682-1691.
- [66] Wang H, Yang M, Zheng N. G2-monodepth: A general framework of generalized depth inference from monocular rgb+ x data[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 46(5):3753-3771.
- [67] Box G E, Tiao G C. Bayesian inference in statistical analysis[M]. John Wiley & Sons, 2011.
- [68] Xu R, Wunsch D. Survey of clustering algorithms[J]. IEEE Transactions on neural networks, 2005, 16(3):645-678.
- [69] Kim Y, Bang H. Introduction to kalman filter and its applications[M]//Introduction and implementations of the Kalman filter. IntechOpen, 2018.
- [70] Gravina R, Alinia P, Ghasemzadeh H, et al. Multi-sensor fusion in body sensor networks: State-of-the-art and research challenges[J]. Information Fusion, 2017, 35:68-80.
- [71] Zhang Y, Wei P, Li H, et al. Multiscale adaptation fusion networks for depth completion[C]//2020

- International Joint Conference on Neural Networks (IJCNN). IEEE, 2020: 1-7.
- [72] Tang J, Tian F P, Feng W, et al. Learning guided convolutional network for depth completion[J]. IEEE Transactions on Image Processing, 2020, 30:1116-1129.
- [73] Liu H, Roznere M, Li A Q. Deep underwater monocular depth estimation with single-beam echosounder.[C]//ICRA. 2023: 1090-1097.
- [74] Roznere M, Li A Q. Underwater monocular image depth estimation using single-beam echosounder [C]//2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2020: 1785-1790.
- [75] Hart P E, Nilsson N J, Raphael B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE transactions on Systems Science and Cybernetics, 1968, 4(2):100-107.
- [76] Stentz A. Optimal and efficient path planning for partially-known environments[C]//Proceedings of the 1994 IEEE international conference on robotics and automation. IEEE, 1994: 3310-3317.
- [77] LaValle S M, Kuffner J J. Rapidly-exploring random trees: Progress and prospects: Steven m. lavalle, iowa state university, a james j. kuffner, jr., university of tokyo, tokyo, japan[J]. Algorithmic and computational robotics, 2001:303-307.
- [78] Knospe C. Pid control[J]. IEEE Control Systems Magazine, 2006, 26(1):30-31.
- [79] Shtessel Y, Edwards C, Fridman L, et al. Sliding mode control and observation: volume 10[M]. Springer, 2014.
- [80] Bounini F, Gingras D, Pollart H, et al. Modified artificial potential field method for online path planning applications[C]//2017 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2017: 180-185.
- [81] Kouvaritakis B, Cannon M. Model predictive control[J]. Switzerland: Springer International Publishing, 2016, 38(13-56):7.
- [82] Hewing L, Wabersich K P, Menner M, et al. Learning-based model predictive control: Toward safe learning in control[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2020, 3(1): 269-296.
- [83] Oquab M, Darcet T, Moutakanni T, et al. Dinov2: Learning robust visual features without supervision [J]. arXiv preprint arXiv:2304.07193, 2023.
- [84] Ranftl R, Bochkovskiy A, Koltun V. Vision transformers for dense prediction[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 12179-12188.
- [85] Birkel R, Wofk D, Müller M. Midas v3. 1—a model zoo for robust monocular relative depth estimation [J]. arXiv preprint arXiv:2307.14460, 2023.
- [86] Wang P, Fan E, Wang P. Comparative analysis of image classification algorithms based on traditional machine learning and deep learning[J]. Pattern recognition letters, 2021, 141:61-67.
- [87] Ahmad M, Shabbir S, Roy S K, et al. Hyperspectral image classification—traditional to deep models:

- A survey for future prospects[J]. IEEE journal of selected topics in applied earth observations and remote sensing, 2021, 15:968-999.
- [88] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. Springer, 2015: 234-241.
- [89] Roy A G, Navab N, Wachinger C. Concurrent spatial and channel ‘squeeze & excitation’ in fully convolutional networks[C]//International conference on medical image computing and computer-assisted intervention. Springer, 2018: 421-429.
- [90] Zhao H, Shi J, Qi X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2881-2890.
- [91] Chen L C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 801-818.
- [92] Badrinarayanan V, Kendall A, Cipolla R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39 (12):2481-2495.